

Disease Track-Dissertationen

QML Klinische Vorhersage: Erklärbarkeit, Treue und Einhaltung des EU-KI-Gesetzes

1. Projektübersicht und wissenschaftliche Motivation

1.1 Kernziel

Dieses Projekt untersucht, ob Quantenmaschinelles Lernen (QML) klinisch vertrauenswürdige Vorhersagen in der Medizin treffen kann – und ob seine Vorhersagen Klinikern so erklärt werden können, dass sie die Transparenz- und Verantwortlichkeitsanforderungen des EU-Gesetzes über künstliche Intelligenz (EU-KI-Gesetz, 2024) erfüllen. Es gilt nicht als gegeben, dass QML das klassische ML übertrifft. Stattdessen bewertet es rigoros sowohl die prädiktiven als auch die erklärenden Eigenschaften von QML im Vergleich zur klassischen ML über sechs Krankheitsdomänen hinweg und nutzt dabei etablierte genetische und molekulare Biologie als unabhängige Grundwahrheit.

Das Projekt ist explizit methodisch orientiert. Sein wissenschaftlicher Beitrag ist nicht die Entdeckung neuartiger Biomarker an sich, sondern die Entwicklung und Validierung eines XAI-Bewertungsrahmens für QML-Klinische Prädiktionsmodelle – einen, der über Krankheitsdomänen und Datenmodalitäten hinweg angewendet werden kann. Wenn das Projekt zufällig neue, biologisch plausible Merkmale identifiziert, die klassische Modelle übersehen, ist das eine sekundäre Erkenntnis.

1.2 Regulatorischer Kontext des EU-KI-Gesetzes

Das EU-KI-Gesetz (2024) klassifiziert KI-Systeme, die bei medizinischer Diagnose, Prognose und Behandlungsempfehlung eingesetzt werden, als Hochrisiko. Die Artikel 13 und 14 verlangen, dass risikoreiche KI-Systeme transparent sind, ihre Ergebnisse von menschlichen Aufsehern interpretierbar sind und dass Kliniker die Beweggründe hinter individuellen Vorhersagen verstehen können. Artikel 9 verlangt, dass Anbieter die ergriffenen Maßnahmen dokumentieren, um eine menschliche Aufsicht sicherzustellen.

Für QML-Systeme zur klinischen Prädiktion stellt dies eine spezifische regulatorische Herausforderung dar: Quantenschaltkreise sind von Natur aus weniger transparent als klassische Entscheidungsbaume oder logistische Regressionen. Die interne Berechnung – Superposition, Verschränkung, Interferenz – hat kein direktes klinisches Pendant. Post-hoc-Attributionsmethoden wie SHAP müssen die Lücke zwischen Quantenberechnung und klinischer Interpretierbarkeit überbrücken. Ob sie dies getreu tun, ist die zentrale empirische Frage dieses Projekts.

Die regulatorische Rahmung in einem Satz

Wenn ein QML-Modell vorhersagt, dass ein Patient innerhalb von drei Jahren an Alzheimer erkrankt, das EU-KI-Gesetz verlangt, dass ein Kliniker verstehen kann, warum – welche Patientenmessungen die Messungen beeinflusst haben

Die Vorhersage, in welche Richtung und mit welcher relativen Bedeutung. Dieses Projekt testet, ob aktuelle XAI-Methoden (SHAP) können dieses Verständnis für QML-Modelle treu vermitteln, und ob das von ihnen vermittelte Verständnis klinisch plausibel ist.

1.3 Warum QML speziell

QML wird in diesem Projekt nicht verwendet, da erwartet wird, dass es klassisches ML übertrifft – die Belege dafür sind in klinischen Kontexten noch dünn und inkonsistent (Gupta et al., npj Digital Medicine, 2024). Vielmehr wird QML verwendet, weil:

1. **Regulatorische Erwartungen:** Quanten-Hardware wird voraussichtlich innerhalb von 5–10 Jahren in den klinischen KI-Einsatz eingeführt. Die Einführung der XAI-Methodik für QML jetzt – vor der Einführung – ist die verantwortungsvolle Vorbereitung.
2. **Theoretischer Interaktionsvorteil:** Quantenkernel kodieren paarweise Merkmalsinteraktionen über Verschränkungsgatter. Bei Krankheiten, bei denen der kausale Mechanismus Gen-Gen- oder Protein-Protein-Interaktionen beinhaltet (wie bei den meisten komplexen Krankheiten), ist dies eine theoretisch motivierte und keine willkürliche Entscheidung.
3. **Kleinstichprobenpotenzial:** Formelle theoretische Ergebnisse (Caro et al., Nature Communications, 2022) zeigen, dass QML-Generalisierungsfehlerskalen im Low-Sample-Regime günstiger sind als klassische ML – relevant für Datensätze seltener Krankheiten und spezialisierte klinische Kohorten.
4. **Literaturlücke:** Bis 2025 wendet praktisch keine veröffentlichte Arbeit XAI-Methoden auf QML-klinische Vorhersagen mit einer formalen klinischen Treuebewertung an. Das ist die Lücke, die das Projekt füllt.

1.4 Vorgegebene klinische Erwartungslisten

Bevor ein Student ein Modell ausführt, muss der Projektleiter die Clinical Expectation List (CEL) für jede Krankheit und Klassifikationsaufgabe vorab festlegen. Der CEL ist eine kurze, gerankte Liste von Merkmalen, die die Fachliteratur als Haupttreiber der Klassifikation festlegt. Es wird in die Schrift der These geschrieben, bevor der Studierende irgendwelche Daten sieht.

Der CEL erfüllt zwei Funktionen: (1) Er definiert den Ground Truth Recovery Test – bewertet SHAP CEL-Merkmale hoch? — und (2) es definiert, was in der Clinical Surprise Rate Bewertung als 'Überraschung' gilt.

Warum die Vorspezifikation wichtig ist

Wenn der CEL nach Sehen der SHAP-Ergebnisse definiert wird, macht der Bestätigungsfehler die Bewertung bedeutungslos.

Der CEL muss gesperrt werden, bevor der Schüler das erste Modell ausführt.

Nicht alle Überraschungen sind gleich. Wenn das primäre Attributionsmerkmal eines Modells nicht auf dem Cel liegt, muss der Schüler die Überraschung in eine von drei Kategorien einteilen:

Typ	Definition	Aktion
Schlechte Überraschung	Das wichtigste Merkmal ist ein bekannter Störfaktor, demografischer Proxy oder Datenartefakt – z. B. Geschlecht in einer eingeschlechtlichen Kohorte, Batch-Variable, Alter als Proxy für alles	Markiere als Modellfehler. Untersuchen Sie, ob die Vorverarbeitung die Störung verursacht hat. Melde die Ergebnisse als Treuefehler.
Mehrdeutige Überraschung	Top-Merkmal ist nicht auf dem CEL, aber biologisch plausibel – z. B. ein Gen im gleichen Weg wie ein CEL-Gen, aber nicht das CEL-Gen selbst	Dokumentieren und interpretieren. Schau dir die STRING-Datenbank oder Pfaddatenbanken auf CEL-Nähe an. Melde dich als 'biologisch proximal, aber unerwartet'. Weder Misserfolg noch Entdeckung.
Interessante Überraschung	Das Top-Merkmal befindet sich nicht im CEL, kein Störfaktor und nicht in einem bekannten, CEL-nahen Pfad – eine potenziell neuartige Verbindung	Flagge als Kandidat für einen neuen Biomarker. Dokumentiere sorgfältig. Beanspruchen Sie KEINE Beweisaufnahme – dies erfordert eine unabhängige Validierung. Berichte als 'hypothesengenerierendes Befund'.

CEL-Funktionen sind in Prioritätsreihenfolge aufgeführt: Tier 1 = muss repariert werden (das Nichterscheinen in Top-20-SHAP für eines der beiden Modelle weist auf einen Vorverarbeitungsfehler oder einen grundlegenden Modellfehler hin); Tier 2 = sollte sich erholen (erwartet in den Top-50, Anwesenheit stärkt die Behauptung der Zeitung); Tier 3 = könnte sich erholen (biologisch plausibel, Anwesenheit ist ein positiver Bonus).

1.5 Proteomik als zweites Merkmalsset

Wenn ein **Proteomik-Datensatz** für dieselbe Patientenpopulation verfügbar ist, muss er als unabhängiges zweites Merkmalsset verwendet werden. Die Begründung: Biomarker-Kandidaten, die durch QML-SHAP durch **Transkriptomik** identifiziert wurden, sind glaubwürdiger, wenn dieselben oder verwandten Proteine ebenfalls aus einer separaten, proteomik-abgeleiteten Merkmalsmatrix als wichtig identifiziert werden. **Die Konkordanz zwischen Transkriptomik-SHAP und Proteomik-SHAP ist eine stärkere Behauptung** als beide allein.

Die Proteomik-Analyse verwendet eine identische Pipeline wie die Transkriptomik-Analyse – gleiche QML-Architektur, gleiche SHAP-Methode, gleiche CEL-Wiederherstellungsbewertung. Die Vergleichstabelle zeigt Feature-Rankings beider Modalitäten nebeneinander. Konkordante Topmerkmale sind die stärksten Biomarker-Kandidaten.

1.6 Keine Leistungsüberlegenheitsansprüche

Keine These in diesem Projekt behauptet, dass QML als primärer wissenschaftlicher Beitrag das klassische ML übertrifft. Die Leistung (AUC, F1, MCC) wird für beide Modelle mit identischen Bewertungsprotokollen und bootstrappeden Konfidenzintervallen gemeldet, aber

Leistungsunterschiede werden als sekundäre Beobachtungen und nicht als Schlagzeilenergebnisse kontextualisiert. Der Hauptbeitrag ist immer der **XAI-Vergleich** – ob die Erklärungen klinisch treu sind, welche Merkmale jedes Modell betont und wie sich die Clinical Surprise Rate vergliert. Allerdings müssen QML-Modelle innerhalb eines bestimmten Qualitätsakzeptanzbereichs innerhalb klassischer ML-Ergebnisse liegen, XAI bei schlechten Modellen ist wertlos, sodass eine vergleichbare Leistung von QML erforderlich ist, um mit XAI fortzufahren.

2. Klinische Plausibilitätsanalyse – Experimentelle Metrik

2.1 Motivation

Die Standard-XAI-Bewertung in der ML-Literatur verwendet globale Metriken: Identifiziert SHAP insgesamt die richtigen Merkmale? Aber die Einhaltung des EU-KI-Gesetzes erfordert Erklärungen auf Patientenebene: Welche Eigenschaften haben für diesen speziellen Patienten die Vorhersage beeinflusst? Ein Modell kann eine ausgezeichnete globale Attribution haben, während es lokal unplausible Erklärungen für einzelne Patienten liefert – insbesondere wenn ein störendes Merkmal (z. B. Alter, Geschlecht, Batch) die Vorhersagen für eine Teilmenge der Patienten dominiert, während ein echtes biologisches Signal andere dominiert.

Die Clinical Surprise Rate (CSR) setzt das Vertrauen der Kliniker auf individueller Vorhersageebene um. Sie wird sowohl für QML als auch für klassisches ML berechnet und verglichen. Ein niedrigeres CSR zeigt, dass die Erklärungen des Modells konsistenter von klinisch erwarteten Merkmalen gesteuert werden – ein besseres Modell für die Einhaltung des EU-KI-Gesetzes.

2.2 Formale Definition

Sei $P = \{p_1, p_2, \dots, p_n\}$ eine Zufallsstichprobe von n Patienten aus dem zurückgehaltenen Testset. Für jeden Patienten- P_i berechnen Sie die lokale SHAP-Erklärung – den signierten SHAP-Wert für jedes Merkmal für die Vorhersage dieses Patienten.

Definiere die Top- k lokalen SHAP-Merkmale als die k Merkmale mit den größten absoluten SHAP-Werten für Patienten- P_i . Sei $k = 3$ für die Primäranalyse (was einem Kliniker in einer kurzen Erklärung gezeigt würde).

Definieren Sie die klinische Erwartungsliste (CEL) wie oben festgelegt – eine Reihe von Merkmalen, die in der Fachliteratur als primäre Treiber der Klassifikation festgelegt werden.

Ein klinisches Überraschungs-Si tritt bei Patient P_i auf, wenn:

5. Keine der drei wichtigsten SHAP-Funktionen für Patient P_i erscheinen auf dem Tier 1 oder Tier 2 CEL, AND
6. Mindestens eines der Top 3 SHAP-Features kann als Bad Surprise klassifiziert werden (bekannter Störer oder Datenartefakt)

Denken Sie daran, Patienten zu analysieren, für die die Vorhersage korrekt ist (wahr positiv oder wahr negativ) – eine Überraschung bei einer falschen Vorhersage ist zu erwarten und nicht informativ.

Die klinische Überraschungsrate lautet: $CSR = |\{pi : Si = 1\}| / |P|$

CSR wird separat für QML und klassisches ML berechnet. Der Hauptvergleich ist CSR (QML) vs. CSR (Classical) auf demselben Testsatz und derselben Patientenstichprobe P.

2.3 Praktische Umsetzung

7. **Patientenstichprobe:** Ziehe P zufällig nur aus korrekten Vorhersagen (wahre positive und wahre Negative) im gehaltenen Testsatz. Korrekte Vorhersagen sind informativer – wenn das Modell die Antwort richtig hat, aber aus dem falschen Grund, ist das ein Treuefehler. Falsche Vorhersagen werden erwartet, ungewöhnliche Merkmalszuweisungen zu haben.
8. **SHAP-Berechnung:** Verwenden Sie Shap. TreeExplainer für RF; Shap. KernelExplainer für QML (modellunabhängig). Für KernelExplainer verwenden Sie 100–200 Hintergrundproben aus dem Trainingsset. Berechnen Sie absolute SHAP-Werte für jedes Merkmal für jeden Patienten.
9. **Wasserfalldiagramme:** Erstellen Sie `shap.plots.waterfall()` für jeden Patienten in P. Dies sind die primären visuellen Ergebnisse der klinischen Plausibilitätsanalyse. Fügen Sie 5–8 repräsentative Beispiele in die These auf (3 nicht überraschend, 2 mehrdeutige Überraschungen, 2 interessante Überraschungen, falls gefunden).
10. **Klassifikation der Überraschungen:** Jede Überraschung wird vom Schüler als Schlecht, Mehrdeutig oder Interessant eingestuft. Die Klassifikation ist in einer ergänzenden Tabelle mit Begründung dokumentiert.
11. **Bootstrap CI:** P 1000 Mal mit Ersatz neu abtasten und CSR für jede Neubeschaffung berechnen. Melde 95 % Bootstrap-CI für CSR. Bei $n=25-30$ ist CI breit – erkennen Sie dies an und überinterpretieren Sie kleine CSR-Unterschiede nicht.

2.4 Interpretationsschwellenwerte

Angesichts der Neuartigkeit dieser Metrik und der kleinen Stichprobengrößen wird folgender Interpretationsrahmen vorgeschlagen. Dies sind keine statistischen Schwellenwerte – sie sind klinische Intuitionsanker für Diskussionen:

CSR-Bereich	Interpretation	Auswirkungen des EU-KI-Gesetzes
0–15%	Erklärungen sind fast immer klinisch plausibel; Das Modell kann darauf vertraut werden, Vorhersagen den erwarteten Merkmalen der meisten Patienten zuzuordnen	Modellerklärungen erfüllen in den meisten Fällen wahrscheinlich die Transparenzanforderungen der Kliniker
15–35%	Gemischte Plausibilität; Einige Patienten erhalten unerwartete primäre Attributionen. Modellspezifische Analyse erforderlich, um Untergruppen zu identifizieren, die Überraschungen verursachen	Erfordert eine Einzelprüfung durch den Kliniker; Eine automatisierte Bereitstellung ohne Aufsicht wird nicht empfohlen

35%+	Erklärungen sind häufig klinisch unglaubwürdig; Das Modell könnte auf Störfaktoren oder unscheinbaren Korrelationen basieren, die aus globalem SHAP nicht ersichtlich sind	Das Modell sollte nicht in klinischen Umgebungen eingesetzt werden, ohne eine umfassende Überarbeitung der Feature-Engineering und Validierung
------	--	--

3. Spezifikation gemeinsamer Pipeline

Alle Krankheitsthesen verwenden dieselbe Rechenpipeline, um Vergleichbarkeit über Krankheitspfade hinweg sicherzustellen und die horizontalen Kombinationsarbeiten zu ermöglichen, sofern sie in den einzelnen Krankheitsabschnitten nicht unterschiedlich definiert sind. Weitere Abweichungen müssen dokumentiert und begründet werden.

3.1 Klassische ML-Basislinie (A-Thesen)

12. **Modelle:** Random Forest (RF) und Support Vector Machine mit RBF-Kernel (SVM-RBF). Beide wurden mit identischer Vorverarbeitung und dem CV-Protokoll trainiert.
13. **Hyperparameter-Tuning:** 5-fache stratifizierte Kreuzvalidierung auf Trainingsset mit RandomizedSearchCV. Dokumentiere alle abgestimmten Parameter und Endwerte.
14. **Auswertung:** Gehaltenes Testset (20 % der Daten, dokumentierter zufälliger Seed). Berichte AUC-ROC, F1, MCC, Präzision, Rückruf mit 95 % Bootstrap-KI (1000 Resamples). Keine Einzahl-Ansprüche ohne CIs.
15. **SHAP:** Shap. TreeExplainer für RF; Shap. LinearExplainer für SVM. Global: Zusammenfassungsdiagramm (Bienenstock), Top-20-Feature-Bedeutungsbalkendiagramm. Lokal: Wasserfall-Plots für P-Patienten.
16. **CEL-Wiederherstellung:** Berechnen Sie $\text{recall}@k$ für $k = 5, 10, 20$ gegen vorgegebene CEL. Berichte in einer standardisierten Tabelle.

3.2 QML-Implementierung (B-Thesen)

17. **Rahmen:** PennyLane (pennylane.ai). Simulator: default.qubit (rauschlos). Dokumentiert die PennyLane-Version.
18. **Architekturen:** QSVM (ZZFeatureMap Quantum Kernel + sklearn SVC mit vorberechnetem Kernel) und VQC (stark verschränkte Schichten Ansatz). Beide wurden auf demselben vorverarbeiteten Datensatz trainiert.
19. **Merkmalscodierung:** Winkelkodierung (Ry-Rotation pro Merkmal). Maximal 20 Features = 20 Qubits. Feature-Auswahl: Top-N aus dem A-Thesis-SHAP-Ranking (wo $N \leq 20$). Dokumentenauswahlkriterium explizit.
20. **Training:** VQC: Adam Optimiser, maximal 200 Epochen, frühes Stoppen bei Validierungsverlust (Geduld = 20). QSVM: Quantenkernel-Matrix einmal berechnet, dann sklearn SVC-Optimierung.
21. **SHAP:** Shap. KernelExplainer (modellunabhängig) für sowohl QSVM als auch VQC. 150 Hintergrundproben aus dem Trainingsset. Die Laufzeit muss vorab gebenchmarkt werden, bevor sie dem Schüler zugewiesen wird.

22. **CSR-Bewertung:** Gleiche Patientenprobe P, die sowohl für QML als auch für klassische ML-SHALP verwendet wird. Dasselbe Wahlergebnis wurde angewendet. Produziert direkt vergleichbare CSR (QML) vs. CSR (klassisch).
23. **Bewertung:** Identisches Protokoll wie A-Thesis. Berichte über Leistungsunterschiede mit Bootstrap-CI und stelle explizit fest, dass der Leistungsvergleich sekundär zum XAI-Vergleich ist.

3.3 Vorverarbeitungsstandards

24. **Regel zur Funktionsbehalte:** Alle Tier-1- und Tier-2-CEL-Features müssen unabhängig vom Varianzrang in der Feature-Matrix beibehalten werden. Dokumentiere das explizit. Verwenden Sie den Varianzfilter NACH manueller Markierung der CEL-Funktionen als behalten.
25. **Normalisierung:** Genexpression: $\log_2(\text{FPKM}+1)$, dann Quantilnormalisierung. Methylierung: M-Werte (Logit von Beta-Werten). Klinische Merkmale: StandardScaler (null Mittelwert, Einheitsvarianz). Genetische Variantenmerkmale (APOE, GBA1 usw.): Ordinalkodierung (0/1/2 für Genotyp-Dosierung) – standardisiert NICHT.
26. **Fehlende Daten:** Dokumentieren Sie das Fehlen nach Merkmal und nach Stichprobe. Für Merkmale, bei denen >20 % fehlen: entfernen. Für Proben mit >30 % fehlenden Merkmalen: entfernen. Für den Rest: MICE-Imputation (sklearn IterativeImputer). Dokumentieren Sie vor und nach der Imputation n.
27. **Zug/Testaufteilung:** 80/20 geschichtete Aufteilung. Zufälliger Seed wurde für alle Dissertationen im Projekt auf 42 festgelegt. Das Testset wird während der Vorverarbeitung oder Hyperparameter-Abstimmung NIEMALS berührt.
28. **Batch-Korrektur:** Beim Zusammenführen von Datensätzen aus mehreren GEO-Zugängen: ComBat (pycombat Python-Paket) wurde ausschließlich auf das Trainingsset angewendet. Wenden Sie das trainingsset-angepasste ComBat-Modell auf das Testset an. Wenden Sie ComBat NICHT auf kombinierten Zug+Test an, bevor Sie aufgeteilt werden – dies stellt Datenleckage dar.
29. **Vorbearbeitungsprotokoll:** Der Student mit einer Abschlussarbeit muss eine preprocessing_decisions.md-Datei erstellen, die jeden Filter-, Imputations- und Normalisierungsschritt mit den Probenzählungen davor und danach dokumentiert. Diese Datei wird mit B- und C-Thesis-Studierenden geteilt.

3.4 Reproduzierbarkeitsstandards

30. Der gesamte Code in GitHub (Projektorganisation) mit MIT-Lizenz. Repository-Struktur: /data (leer, mit Download-Anweisungen), /preprocessing, /classical_ml, /qml, /xai, /evaluation
31. Alle zufälligen Seeds wurden korrigiert und dokumentiert: numpy seed 42, sklearn seed 42, PennyLane Device Seed 42
32. Umgebung: Conda environment.yml Datei, die alle Paketversionen spezifiziert. Getestet mit Python 3.13
33. Laufzeit: Dokumentations-Wanduhrzeit für jeden wichtigen Schritt auf dem Projekt-Computer-Server. Markiere jeden Schritt, der mehr als 2 Stunden überschreitet.
34. Reproduzierbarkeitsprüfung: Nach Abschluss der Dissertation führt eine zweite Person (Betreuer oder Peer) die gesamte Pipeline aus den Rohdaten durch und überprüft, ob die Ergebnisse innerhalb der Gleitkommatoleranz übereinstimmen

4. Überblick: Zeitpläne & Prio

[illegible]

Krankheitsspur 1: Brustkrebs

Datensatz: TCGA-BRCA (mRNA FPKM-UQ + Illumina 450k Methylierung + somatische Mutationsrufe + BRCA1/2 Keimbahnstatus). Replikation: METABRISCH. Proteomics zweites Feature-Set: TCGA RPPA (~400 Proben).

Klassifikationsaufgabe: PAM50 Basal-ähnlich im Vergleich zu allen anderen Untertypen (Luminal A + Luminal B + HER2-angereichert). Diese Aufgabe prognostiziert eine validierte molekulare Schichtung, die die Eignung von PARP-Inhibitoren und die Berücksichtigung einer Platin-Chemotherapie bestimmt – was in allen Zentren nicht routinemäßig verfügbar ist.

Ground-Truth-genetische Marker

35. **BRCA1 (17q21) & BRCA2 (13q12):** Keimlinienpathogene Varianten bringen ein lebenslanges Brustkrebsrisiko mit sich. Der somatische Verlust der Heterozygotie in Tumoren führt zu einem homolog-rekombinationsdefizienten (HRD) Phänotyp. BRCA1-mutante Tumore gruppieren sich eng in den dreifach-negativen / basal-ähnlichen Subtyp – ein starkes, replizierbares Klassifikationssignal.
36. **PIK3CA, TP53, CDH1, PTEN, PALB2:** Ko-occurrende Treiber mit gut charakterisierten Signalwegrollen; PALB2 ist ein bekannter BRCA1/2-Interaktor und ein wichtiger sekundärer Marker.
37. **PAM50-Gensignatur:** 50-Gen-Panel, das Luminal A, Luminal B, HER2-angereicherte, Basal-ähnliche, Normal-ähnliche Subtypen definiert – dient als validierte Multi-Gen-Grundwahrheit, die Ihr Modell teilweise wiederherstellen sollte.

Überlegungen:

38. Der BRCA1/2-Status ist in TCGA-BRCA gut annotiert, sowohl mit Keimlinien- als auch mit somatischen Rufen
39. Bekannte Subtyp-Genotyp-Assoziationen liefern eine mehrstufige Grundwahrheit: Genebene (BRCA1/2) und Signaturebene (PAM50)
40. Die BRCA-Kohorte ist der am meisten ML untersuchte TCGA-Datensatz – umfangreiche klassische Baselines existieren zum Vergleich
41. Saggi et al. verwendeten TCGA-Lunge; Die Verwendung von TCGA-BRCA differenziert Ihre Arbeit und ist besser validiert

Wegweisende Arbeiten

42. [Miki et al. \(1994\) — Ein starker Kandidat für das Brust- und Eierstockkrebs-Gen, BRCA1](#) Science. Das ursprüngliche BRCA1-Klonpapier. ~16.000 Zitate. Zitiere als historische Grundlage.
43. [Wooster et al. \(1995\) — Identifikation des Brustkrebsanfälligkeitgens BRCA2](#) Nature. Ursprüngliches BRCA2-Klonen. ~7.000 Zitate.
44. [Cancer Genome Atlas Network \(2012\) — Umfassende molekulare Porträts menschlicher Brusttumore](#), Nature. Das maßgebliche TCGA-BRCA-Papier; Etabliert PAM50-Subtypen, BRCA-Mutationslandschaft und Multi-Omics-Integration. Wesentliche Referenz für jede TCGA-BRCA-Studie.
45. Wen et al. (2019) — Assoziation von BRCA1/2-Mangel mit Mutationslast und Immuninfiltrationen in PLoS ONE, 91 Zitationen. Zeigt, dass BRCA1/2-defiziente Tumore unterschiedliche Immunsignaturen aufweisen – relevante zusätzliche Wahrheit.

Datensätze

Datensatz	Inhalt	Zugang	Anmerkungen
TCGA-BRCA	1.098 Tumore · mRNA, miRNA, DNA-Methylierung, CNA, somatische Mutationen, Keimlinien-BRCA-Status	portal.gdc.cancer.gov – kostenlos	Goldstandard. Download über das TCGAbiolinks R-Paket. BRCA-Keimlinienanrufe verfügbar.
METABRISCH	1.980 Tumore · mRNA + CNA + klinisch + Überleben · Europäische Kohorte	cbioportal.org – kostenlos	Unabhängige Replikationskohorte. Ideal, um QML-Feature-Rankings zu validieren.
GEO GSE96058 (SCAN-B)	3.273 Brusttumore · RNA-seq · bevölkerungsbasiertes Schweden	ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE96058 – kostenlos	Große Bevölkerungskohorte. Gut geeignet, um die Generalisierbarkeit von QML-identifizierten Merkmalen zu testen.

BC-A TCGA-BRCA	Multi-Omics-Feature-Attribution und klinische Erklärbarkeit in der basal-ähnlichen Brustkrebsklassifikation	BSc BSc · 4–5 Monate
--------------------------	--	--------------------------------

Klassischer ML-Baseline und SHAP-Attribution bei basal-ähnlichem Brustkrebs

FORSCHUNGSFRAGE

Welche Multi-Omics-Merkmale identifiziert klassisches ML (Random Forest, SVM-RBF) als am meisten diskriminierend für die PAM50-Basal- vs. Other-Subtyp-Klassifikation in TCGA-BRCA, und stellt die SHAP-Attribution die vordefinierten CEL-Merkmale – basale Zytokeratine (KRT5/17/14), EGFR und BRCA1/2-Pathway-HRD-Gene – als Haupttreiber zurück?

BEGRÜNDUNG FÜR KLINISCHE NÜTZLICHKEIT

Die PAM50-Subtypisierung (Prosigna-Assay) kostet 2.000–3.000 € und ist in vielen Zentren nicht verfügbar. Die basalähnliche Identifikation bestimmt die Eignung für platinbasierte Chemotherapie und PARP-Inhibitoren bei BRCA1/2-mutierten Patienten. Ein Multi-Omics-Modell, das eine vergleichbare Subtypidentifikation aus Standardsequenzierungsdaten erreicht, hätte direkten klinischen Wert.

ZIELE

46. Laden Sie TCGA-BRCA herunter und vorbereiten: mRNA (FPKM-UQ), Illumina 450k Methylierung, somatische Mutation MAF, BRCA1/2 Keimbahnstatus (binäres Merkmal, KEIN Label). Behalte alle Tier 1/2 CEL-Gene, unabhängig vom Varianzrang.

47. Führe eine 80/20 stratifizierte Aufteilung durch (Seed 42). Varianzfilter (Top 2.000 mRNA + Top 500 Methylierungsmerkmale) nach der verpflichtenden CEL-Merkmalserhaltung anwenden. Dokumentiere alle Probenzahlen vor und nach jedem Filterschritt.
48. Train Random Forest und SVM-RBF mit fünffach geschichtetem CV auf dem Trainingsset; Bewerten Sie das aufgeteilte Testset. Berichte AUC-ROC, F1, MCC mit 95 % Bootstrap-KI (1000 Resamples).
49. SHAP anwenden: TreeExplainer für RF; LinearExplainer für SVM. Berechnen Sie globale $\text{recall}@k$ für $k=5,10,20$ gegen vorgegebenen CEL. Erstellen Sie eine SHAP-Zusammenfassung und ein Top-20-Wichtigkeitsdiagramm der Merkmale.
50. Replizieren Sie auf METABRIC (gleiche Pipeline, gleiche CEL-Bewertung), um die Generalisierbarkeit zu bewerten.
51. Erstellen Sie preprocessing_decisions.md- und geteilte Datensatzdateien für BC-B und BC-C.
52. Optional: Überprüfen Sie die Ergebnisse im Proteomik-Datensatz.

METHODEN

- **Datenzugriff:** *GDC Data Portal portal.gdc.cancer.gov — sofort, kostenlos. TCGAbiolinks R-Paket für programmatischen Download.*
- **CEL-Merkmal-Erhaltung:** *Vor dem Varianzfilter markieren Sie KRT5, KRT17, KRT14, EGFR, ESR1, PGR, MKI67, CDK1, FOXC1, RAD51, PALB2, FANCD2, BRCA1 als befreit. Varianzfilter nur auf die verbleibenden Merkmale anwenden.*
- **Batch/Normalisierung:** *mRNA: $\log_2(\text{FPKM}+1)$, dann Quantilnormalisierung. Methylierung: M-Werte. BRCA1/2 Mutationsstatus: binär 0/1.*
- **SHAP:** *Globale Zusammenfassung (Bienenenschwarm) und Top-20-Takt. Recall@k Tisch gegen CEL. Lokal: Wasserfalldiagramme für 50 zufällig ausgewählte korrekte Vorhersagen aus dem Testset – als Eingabe für die BC-B Klinische Plausibilitätsanalyse.*
- **Proteomics-Vorschau:** *Laden Sie TCGA-RPPA-Daten für Proben mit abgestimmter mRNA herunter. Überprüfen Sie die Überlappung der Stichproben (~400). Stellen Sie die zusammengeführte Datei für BC-B bereit.*

LIEFERERGEBNISSE

- Vorverarbeiteter Datensatz (HDF5): mRNA + Methylierung + Mutationsmerkmale + PAM50-Etiketten. Geteilt mit BC-B und BC-C.
- SHAP recall@k Tabelle (RF und SVM) gegen CEL – die Basislinie, die jede nachfolgende Arbeit ausdehnt.
- preprocessing_decisions.md dokumentiert jeden Filterschritt mit Sample-Counts.
- 50 lokale SHAP-Wasserfalldiagramme (anonymisiert) – an BC-B zur klinischen Plausibilitätsanalyse übergeben.
- METABORISCHE Replikationsergebnisse.

VORAUSSETZUNGEN (STUDENT)

- Python (Pandas, scikit-learn, shap). R basic (TCGAbiolinks, Limma). Kein QML erforderlich.
- Liest: TCGA-BRCA 2012 Nature-Artikel; Miki 1994 BRCA1; Guinney 2015 (zum Kontext zu PAM50).

Tier	Merkmal / Gen	Begründung
1	KRT5, KRT17, KRT14	Basale Cytokeratine — kanonische basalähnliche Marker in der PAM50-Signatur; sehr spezifisch für diesen Subtyp
1	EGFR	Überausgedrückt in Basal-ähnlich; einer der stärksten Einzeldiskriminatoren zwischen Subtypen
1	ESR1, PGR (negativ)	ER/PR-Negativität definiert Basal-ähnlich; muss mit stark negativen SHAP-Werten für diese Klasse erscheinen
2	BRCA1-Mutationsstatus / BRCA1-Expression	BRCA1-Mutanten-Tumore sammeln sich überwältigend zu Basal-ähnlichen Tumoren; Lyssenko-Analogon bei Brustkrebs
2	MKI67, CDK1, FOXC1	Marker mit hoher Proliferation, die für basale Marker charakteristisch sind; Teil des PAM50-Panels
2	BRCA1/2-Pfad: RAD51, PALB2, FANCD2	HRD-Signaturgene – stromabwärts von BRCA1/2 Funktionsverlust; Erwartet in einer basalähnlichen Vorhersage
3	MLH1-Methylierung	Methylierungs-Silencing tritt manchmal zusammen mit basalartigem Verhalten auf; Anwesenheit ist ein Bonus

Checkliste zur Vorbereitung von Betreuern für BC-A

Woche 1: TCGA-BRCA-Manifest herunterladen; Verifizieren Sie die TCGA Biolinks-Pipeline End-to-End. Pre-Extraction BRCA1/2 Keimbahnaufrufe aus dem Ellrott et al. Supplement 2018.

Woche 1: METABRIC von cBioPortal herunterladen (keine Registrierung). Überprüfen Sie die verfügbaren PAM50-Etiketten.

Woche 2: TCGA RPPA-Daten herunterladen; Probenüberlappung mit dem mRNA-Datensatz bestätigen (~400 Proben).

Woche 2: Definiere CEL.

Woche 3: Durchsehen preprocessing_decisions.md-Entwurf. Überprüfen Sie die erhaltenen CEL-Gene, bevor der Varianzfilter angewendet wird.

BC-B TCGA-BRCA + RPPA	Bewertung klinischer Plausibilität und Merkmalsinteraktionen im Quanten-Maschinellen Lernen für Brustkrebs-Subtypisierung	BSc/MSc BSc/MSc · 5–6 Monate
------------------------------------	--	--

QML-Implementierung, SHAP-Vergleich und klinische Plausibilitätsanalyse

FORSCHUNGSFRAGE

Erreicht ein Quantenklassifikator (QSVM, VQC), der auf Brustkrebs-Multiomics-Daten angewendet wird, eine Leistung innerhalb des 95%-KI der klassischen ML – und wenn doch, identifizieren seine SHAP-Erklärungen verschiedene Biomarkerkandidaten, und sind diese Erklärungen klinisch mehr oder weniger plausibel als klassische ML-Erklärungen, wie sie durch die klinische Plausibilitätsanalyse auf individuelle Patientenvorhersagen bewertet werden?

PERFORMANCE GATE

Mindestleistungskriterium (gilt für alle B-Thesen)

Die klinische Plausibilitätsanalyse und der XAI-Vergleich werden vollständig NUR interpretiert, wenn die QML-Leistung erfolgt

(AUC-ROC) liegt innerhalb des 95%-Bootstrap-KI der klassischen ML-Leistung im Hold-out-Testset.

Wenn die QML-Leistung unter die untere CI-Grenze fällt, wird der XAI-Vergleich als explorativ dargestellt mit explizitem Vorbehalt: 'Der klinische Nutzen des Modells ist nicht belegt; Diese Zuordnungen spiegeln eine

ein unterperformendes Modell und sollte nicht zur Grundlage von Biomarker-Behauptungen verwendet werden.'

Leistungsvergleiche werden immer gemeldet – es ist eine Erkenntnis in beide Richtungen.

ZIELE

53. Implementiere QSVM (ZZFeatureMap Quantenkernel + sklearn SVC vorberechneter Kernel) und VQC (stark verschränkte Schichten, Adam Optimiser) in PennyLane default.qubit. Feature-Input: Top-20 aus dem BC-A RF-SHAP Ranking. Wenn eine Tier-1-CEL-Funktion zwischen den Ränge 21 und 30 liegt, fügen Sie sie auf und dokumentieren Sie diese Entscheidung. Hinweis: Genetische Variantenmerkmale (APOE, GBA1 usw.): sind üblicherweise ordinal kodiert (0/1/2 für Genotypdosierung) und müssen im [-1,1]-Bereich für die Winkelkodierung neu kodiert werden.
54. Performance-Gate prüfen: Vergleichen Sie QML AUC mit BC-A klassischem AUC unter Verwendung von Bootstrap CI Overlap. Dokumentiere das Ergebnis explizit, bevor du mit der XAI-Analyse übergehst.
55. Wenden Sie SHAP (KernelExplainer, 150 Hintergrundproben) auf QSVM und VQC an. Berechnen Sie recall@k gegen CEL. Vergleichen Sie die BC-A SHAP-Rankings mit Rank-Biased Overlap (RBO).
56. Klinische Plausibilitätsanalyse: Mit den 50 Patienten-Wasserfalldiagrammen aus BC-A erstellen Sie abgestimmte QML-Wasserfalldiagramme für dieselben Patienten. Klassifizieren Sie das Top-3-SHAP-Merkmal jedes Patienten als CEL-konsistent, Mehrdeutige Überraschung oder Interessante Überraschung. Vergleichen Sie die Anteile zwischen klassischem und QML. Formulieren Sie dies als beschreibende Fallbeweise, nicht als inferenziellen Vergleich.
57. Proteomics zweites Merkmal: QSVM auf TCGA RPPA-Merkmalen trainieren (Top-15 nach Varianz zu Proteinmerkmalen; alle Tier 1/2 CEL-Proteine behalten). Wenden Sie SHAP an. Erstellen Sie eine Konkordanztafel: Welche Merkmale erscheinen sowohl in Transkriptomik-SHAP als auch in Proteomik-SHAP-Top-20?
58. Rauschempfindlichkeitsexperiment: QSVM standardmäßig erneut ausführen. Mixed-Simulator mit depolarisierender Rauschrate $p=0,001, 0,005, 0,01$. Berichte darüber, ob sich SHAPs Top-10-Rankings über die Lärmpegel hinweg erheblich verändern. Dokumentieren Sie als Einschränkungsanalyse.

METHODEN

- **QML-Framework:** PennyLane; default.qubit (rauschfreier Primär), default.mixed (Rauschempfindlichkeit). Dokumentversion. Alle Quantenschaltungsberechnungen wurden auf klassischem Simulator durchgeführt – nicht auf Quantenhardware.
- **Merkmalkodierung:** Winkelkodierung: $Ry(xi \cdot \pi)$ für Qubit i . Maximal 20 Features = 20 Qubits. StandardScaler, der vor der Codierung angewendet wurde (entscheidend: Features müssen im [-1,1]-Bereich für die Winkelkodierung liegen).

- **QSVM-Kernel:** `ZZFeatureMap` `reps=2`. Kernel-Matrix einmal berechnet; `sklearn SVC(kernel='precomputed')`. C-Parameter auf dem Trainingsset abgestimmt.
- **VQC:** `StronglyEntanglingLayers` Ansatz, 3 Layers, Adam `lr=0,01`, maximal 200 Epochen, frühzeitige Stopp-Patience=20 bei Validierungsverlust (15 % des Trainingssets für die Validierung gehalten).
- **SHAP:** `Shap. KernelExplainer`. Hintergrund: 150 zufällige Trainingsproben. Die Laufzeit muss vom Betreuer vorab gebenchmarkt werden, bevor die Abschlussarbeit beginnt. Wenn die Laufzeit >4 Stunden für 50 Patienten dauert, reduzieren Sie den Hintergrund auf 75 und dokumentieren.
- **RBO:** `rbo Python Package`. `p=0,9` (Top-10 gewichtet). Vergleichen Sie RF vs QSVM und RF vs VQC.
- **Hinweis zur Batch-Korrektur:** TCGA-BRCA ist eine Ein-Kohorte, daher ist eine Batch-Korrektur nicht erforderlich. METABRIC-Replikation verwendet das Batch-Korrekturprotokoll von BC-A.

LIEFERERGEBNISSE

- Performance Gate-Bericht: QML vs. klassisches AUC mit 95 % Bootstrap-CI – explizite Pass/Fail-Anweisung.
- SHAP recall@k Tabelle: RF vs QSVM vs VQC gegen CEL.
- RBO-Analyse: Merkmals-Ähnlichkeit zwischen Quanten- und klassischen Modellen.
- Klinische Plausibilitätsanalyse: Tabelle mit 50 Patienten × (klassisch Top-3, QML Top-3, Klassifikation: CEL-konsistent / Mehrdeutig / Interessant). Repräsentative Wasserfalldiagramme (3 CEL-konsistent, 2 mehrdeutig, 2 interessant, falls gefunden).
- Proteomik-Konkordanztafel: Transkriptomik-SHAP Top-20 vs. RPPA-SHAP Top-20 Überschneidungen.
- Geräuschempfindlichkeitsbericht: SHAP-Rangkorrelation zwischen rauschfreien und verrauschten Schaltungen.

VORAUSSETZUNGEN (STUDENT)

- Python-kompetent; BC-A-Datensatz zum Beginn der Dissertation verfügbar; PennyLane-Selbststudium (2-wöchiges Onboarding geplant).
- Lies: Havlíček et al. 2018 (Nature); Abdulsalam 2023 (QSV+SHAP); Heese 2023 (Gate Shapley zur Einordnung).
- Explizit zusammengefasst: Der Hauptbeitrag ist der XAI-Vergleich, nicht die Leistungsüberlegenheit.

Betreuernotizen für BC-B

Pre-Benchmark KernelExplainer-Laufzeit auf deinem Server, bevor der Student beginnt. 50 Patienten × 150 Hintergrund

Proben × 20 Merkmale auf einem QSVM dauern typischerweise 2–4 Stunden. Wenn >4 Stunden, reduzieren Sie die Hintergrundproben.

Das Geräuschempfindlichkeitsexperiment verwendet `default.mixed` – prüfe, ob dies in deiner PennyLane-Version installiert ist.

Der Vergleich des 50-Patienten-Wasserfalldiagramms ist das klinische Herzstück dieser These.

Klassifizieren Sie alle Überraschungen gemeinsam mit dem Schüler – überlassen Sie das nicht allein.

Wenn das Performance Gate versagt (QML deutlich unter dem klassischen Wert): Melden Sie diese Erkenntnis deutlich.

Es ist ein gültiges und veröffentlichungsfähiges Ergebnis: QML schneidet auf diesem High-n-Datensatz unterdurchschnittlich ab.

BC-C TCGA-BRCA + synthetisch	Gate-Level Shapley-Attribution und Entanglement-Signal-Wiederherstellung in quantenmechanischen Brustkrebsklassifikatoren	MSc MSc · 6 Monate
---	--	------------------------------

FORSCHUNGSFRAGE

Identifizieren Gate-Level Shapley-Attributionen (quantennative XAI) andere wichtige Merkmale als Output-Level SHAP in einem VQC, der für Basal-ähnliche Brustkrebsvorhersage trainiert ist – und speziell: Verändert das Entfernen von Entangling Gates, welche Merkmale als wichtig zugeschrieben werden, und liefert Hinweise darauf, dass Verschränkung zur Merkmalsensibilität des Modells über das hinausgeht, was post-hoc klassische SHAP erkennen kann?

HINTERGRUND

BC-B wendet SHAP auf die Ausgaben des QML-Modells an – und behandelt das Modell als Black Box. Diese Dissertation implementiert Gate-Level-Shapley-Werte (nach Heese et al. 2023, Quantum Machine Intelligence), um einzelnen Quantengattern Bedeutung zuzuschreiben und durch sie den Eingabemerkmalen, auf die diese Gatter wirken. Die entscheidende Frage ist, ob Gate-Level-Attribution eine andere Geschichte erzählt als output-Level SHAP. Das Ablationsexperiment (Verschränkung entfernen, Attribution erneut durchführen) testet, ob Verschränkung speziell für Unterschiede verantwortlich ist.

ZIELE

59. Implementiere das Heese et al. Gate Shapley-Framework in PennyLane für den VQC, der in BC-B ausgebildet wurde. Für jedes Gatter g wird die Änderung der Modellausgabe berechnet, wenn g durch die Identität ersetzt wird – Shapley-gewichtet über alle Koalitionen hinweg.
60. Synthetisches Interaktionsexperiment (verpflichtender erster Schritt): Konstruktiver Datensatz mit eingepflanzter XOR-Interaktion zwischen Merkmalen auf den Rängen 5 und 6 im CEL (geringe marginale Varianz, hohe Gelenkvarianz). Testen Sie, ob Gate Shapley beide Interaktionspartner wiederherstellt; Testen Sie, ob der Output-SHAP sie wiederherstellt. Vergleichen Sie die Erholungsraten.
61. Ablationsexperiment: VQC auf dem BC-B-Datensatz neu trainieren, wobei alle CNOT/CZ-Verschränkungsgatter entfernt werden. Wenden Sie sowohl Gate-Shapley als auch SHAP aus. Vergleichen Sie Top-10-Feature-Rankings zwischen verschränkten und nicht verschränkten Strecken.
62. Dreifachvergleich: klassisches SHAP (BC-A) vs. Output-SHAP (BC-B) vs. Gate-Shapley (diese These). Wo stimmen sie sich bei der Basal-ähnlichen Merkmalzuschreibung einig oder uneinig?

63. Biologische Interpretation von Gate-Shapley-einzigartigen Merkmalen: Merkmale, die durch Gate Shapley identifiziert werden, aber kein Output-SHAP – sind sie STRING-DB-Interaktoren von CEL-Genen? Sind sie in HRD- oder BRCA1/2-nahen Pfaden?

METHODEN

- **Gate Shapley:** *Implement aus Heese et al. 2023. Für eine Schaltung mit G-Gattern erfordert die exakte Berechnung 2^G Vorwärtsdurchgänge – nur für $G \leq 15$ möglich. Verwenden Sie eine Abtastmethode-Approximation (Castro et al.-Methode) für größere Schaltungen. Dokumentannäherungsfehler.*
- **Synthetisches Experiment:** *sklearn.datasets.make_classification mit 2 XOR-wechselwirkenden Merkmalen + 498 Rauschmerkmalen. $n=500$. Überprüfen Sie, dass Gate Shapley das gepflanzte Paar wiederherstellt, bevor Sie echte Daten berühren.*
- **Ablation:** *PennyLane-Schaltungsmodifikation, bei der alle CNOT/CZ entfernt werden. Von Grund auf neu trainieren. Vergleiche mit Kendalls τ -Rang-Korrelation zwischen verschränkten und nicht-verschränkten Top-20-Feature-Listen.*
- **STRING DB:** *Python-StringDB-Bibliothek. Abfrage von Gate-Shapley-einzigartigen Merkmalen gegen CEL-Gene. Konfidenzgrenze $\geq 0,7$. Berichte über das Verhältnis mit bekannten PPI-zu-CEL-Genen im Vergleich zu einem zufälligen Baseline (Permutationstest, 1000 Permutationen).*
- **Hinweis zur Interaktionsbehauptung:** *ZZFeatureMap enthält paarweise Produktterme in seiner Merkmalskarte, die MÖGLICHERWEISE die Erfassung der Interaktionsstruktur ermöglichen. Ob sich dies in Attributionen manifestiert, ist eine empirische Frage, die diese These prüft – keine angenommene Eigenschaft.*

LIEFERERGEBNISSE

- Open-Source-PennyLane-Gate-Shapley-Implementierung (GitHub — primärer zitierbarer Codebeitrag).
- Ergebnisse des synthetischen Experiments: Wiederherstellungsrate der gepflanzten Interaktionsmerkmale durch Gate Shapley vs. Ausgangs-SHAP.
- Ablationsergebnis: Kendalls τ zwischen verschränkten und nicht verschränkten Attributionsranglisten.
- Dreifach-Vergleichstabelle auf TCGA-BRCA.
- STRING-DB-Anreicherungsanalyse für gate-Shapley-einzigartige Merkmale.

Betreuernotizen für BC-C

Gate Shapley ist rechenintensiv. Testen Sie vor der Zuweisung auf einer 4-Qubit-8-Gate-Spielzeugschaltung.

Das synthetische Experiment ist nicht verhandelbar – es muss der realen Datenanalyse vorausgehen. Wenn der exakte Shapley für den vollen Stromkreis unhandreichbar ist ($G > 15$), verwenden Sie eine Abtastungsapproximation und Dokumentfehler.

Die Open-Source-Code-Veröffentlichung ist der wissenschaftliche Beitrag, der dieses Paper zitierbar macht.

Rückfall: Wenn Gatter-Shapley sich als unlösbar erweist, verwenden Sie Qubit-Mutual Information (von-Neumann-Entropie) zwischen dem Ausgangsqubit und jedem Eingangsqubit) als quantennatives Attributionssignal.

Krankheitsspur 2: Alzheimer-Krankheit

Datensatz: ADNI (Liquor-Biomarker + Plasma-Olink-Proteomik + APOE ϵ 4-Genotyp als 0/1/2-Merkmal + kognitive Werte + Hippocampusvolumen). Zugang: adni.loni.usc.edu (kostenlos, Registrierung ~2 Wochen). ADNIMERGE R-Paket.

Klassifikationsaufgabe: MCI-zu-AD-Umwandlung – Vorhersagen, welche MCI-Patienten innerhalb von 36 Monaten AD entwickeln bzw. stabil bleiben. Dies ist ein wirklich ungelöstes klinisches Problem; Es gibt keinen billigen, zuverlässigen Test.

Genetische / molekulare Marker der Grundwahrheit

64. **APOE ϵ 4 (19q13.32):** Das dominante genetische Risikoallel für spät einsetzende AD. ϵ 4 Heterozygoten tragen ein erhöhtes Risiko von ~3–4 $\times$; ϵ 4/ ϵ 4 Homozygoten ~15–25 $\times$ (Saddiki et al. 2020). Fortea et al. (2024) schlugen APOE4/4-Homozygotie als eigenständige genetische Form von AD vor – nahezu vollständige Durchdringung bis zum Alter von 65 Jahren.
65. **ATN-molekulare Biomarker:** Das etablierte klinische Framework — Amyloid (A β 42/40-Verhältnis, Amyloid-PET), Tau (p-tau181, tau PET), Neurodegeneration (Gesamt-Tau, NfL, Hippocampusvolumen). Jedes QML-Modell, das mit ADNI-Daten arbeitet, sollte diese als Top-Funktionen wiederherstellen.
66. **Plasma-Biomarker (neuer):** p-tau181, p-tau217, GFAP, NfL – blutbasierte Marker, die zunehmend als zugängliche Stellvertreter für den CSF/PET-Goldstandard validiert werden. APOE ϵ 4 ist signifikant mit allen außer NfL assoziiert (Stevenson-Hoare et al. 2022).
67. **Polygenes Risiko über APOE hinaus:** GWAS hat ~90 zusätzliche Loci identifiziert. Die ATN-stufenabhängige PRS-Analyse (Altmann et al. 2024) zeigt, dass APOE die frühe Amyloidansammlung dominiert; PRS über APOE hinaus wird für den Tau-Übergang relevant – eine subtile Interaktionsstruktur, die ein Quantenkern erfassen könnte.

Wegweisende Arbeiten

68. [Corder et al. \(1993\) — Gen-Dosis des Apolipoprotein-E-Allels Typ 4 und das Risiko für Alzheimer](#) Science, ~7.000 Zitationen. Die ursprüngliche APOE4-AD-Assoziationsstudie. Immer zitieren.
69. Fortea et al. (2024) — Die APOE4-Homozygotie stellt eine eigenständige genetische Form der Alzheimer-Krankheit dar. Nature Medicine, 188 Zitate. Nahezu vollständige Durchschlagsbefunde; definiert APOE4/4 als genetische AD-Form.
70. Stevenson-Hoare et al. (2022) — Plasma-Biomarker und Genetik bei der Diagnose und Vorhersage des AD-Gehirns, 117 Zitate. Best-Practice-Plasma-Biomarker-Panel; AUC=0,81 kombiniert APOE + A β 42 + GFAP + NfL. Verwenden Sie als Feature Importance Benchmark.
71. Altmann et al. (2024) — Hin zum kaskadierenden genetischen Risiko im Alzheimer-Syndrom (ATN-Stadieneinteilung) Gehirn, 6 Zitate. Zeigt, dass APOE den Übergang von A- zu A+ dominiert; PRS dominiert A+ bis T+ – eine stufenabhängige Interaktionsstruktur, die ideal ist, um zu testen, ob QML sie erfasst.
72. Jackson et al. (2024) — Facettenreiche Rollen von APOE in der Alzheimer-Krankheit Nature Reviews Neurology, 90 Zitationen. Umfassende mechanistische Überprüfung; nützlich für die biologische Interpretation jeglicher QML-identifizierten Merkmale.

Atasets

Datensatz	Inhalt	Zugang	Anmerkungen
ADNI (Alzheimer-Krankheits-Neuroimaging-Initiative)	2.000+ Teilnehmer · Longitudinale Liquor (A β 42, tau, p-tau), Plasma-Biomarker, MRT, PET, Genetik (APOE-Genotyp, GWAS-Arrays), kognitive Scores	adni.loni.usc.edu – kostenlos, Registrierung erforderlich (~2 Wochen)	Goldstandard für AD-Biomarker-Studien. APOE-Genotyp ist für alle Probanden verfügbar. Häufig verwendet in ML-Benchmarks (siehe Zhang et al. MRF-IMD Paper 2025).
AIBL (Australische Bildgebung, Biomarker und Lebensstil)	1.100+ Teilnehmer · PET-Amyloid, MRT, Liquor, Blutbiomarker, kognitive Bewertungen · Längsschnitt	aibl.org.au – kostenlos, Registrierung erforderlich	Unabhängige Replikationskohorte zu ADNI. Kleiner, aber gut kuratiert; Gut für Generalisierbarkeitstests.

AD-A ADNI

Interpretierbares maschinelles Lernen zur Vorhersage der MCI-zu-Alzheimer-Umwandlung mithilfe von Kern-Biomarkern

BSc
BSc · 4–5 Monate

Klassische ML-Basislinie für die Vorhersage der MCI-zu-AD-Konvertierung

FORSCHUNGSFRAGE

Welche klinischen, genetischen und Biomarker-Merkmale identifiziert klassische ML als am voraussprechendsten für die MCI-zu-AD-Umwandlung bei ADNI, und bewertet die SHAP-Attribution den APOE- ϵ 4-Genotyp und die ATN-Biomarker (A β 42, p-tau181, NfL, GFAP) als primäre Treiber – im Einklang mit dem vorgegebenen CEL und der bekannten stufenabhängigen Struktur des AD-genetischen Risikos?

KRITISCHER CEL-TEST

Nicht verhandelbare Wahrheitsprüfung vor Ort

Der APOE ϵ 4-Genotyp MUSS in den Top 3 SHAP-Funktionen zur MCI-Konversionsvorhersage erscheinen. Wenn nicht, deutet dies auf einen Vorverarbeitungsfehler hin (Feature nicht korrekt codiert, Datenzusammenführungsfehler oder Stichprobenauswahl-Bias) – kein interessantes Nullergebnis. Verifizieren Sie den APOE ϵ 4-Rang, bevor weitere Analysen gemeldet werden.

ZIELE

73. Zugang zu ADNI über adni.loni.usc.edu. Verwenden Sie das ADNIMERGE R-Paket, um Tabellen zu verknüpfen. Definieren Sie MCI-Konverter: MCI bei Ausgangspunkt + AD-Diagnose innerhalb von 36 Monaten anhand der DXSUM-Tabelle. Stabile MCI: MCI zu Ausgangspunkt, keine AD nach 36 Monaten. Dokumentiere n pro Gruppe.
74. Merkmale: APOE ϵ 4-Genotyp (0/1/2 Ordinal — NICHT standardisieren), CSF A β 42, A β 40, A β 42/40-Verhältnis, p-tau181, Gesamttau, Plasma NfL, Plasma-GFAP, Hippocampusvolumen (UCSFFSX-Tabelle), MMSE, ADAS-Cog, Alter, Geschlecht,

Schuljahre. Fehlende Daten handhaben: MICE-Imputation nach 80/20-Split (nur auf dem Trainingsset passenden Imputer).

75. Zug-RF und SVM-RBF; SHAP anwenden; Überprüfen Sie, ob APOE ϵ 4 Top-3 ist. Melde ATN-Biomarker recall@k gegen CEL.
76. Stufenabhängiger Test (Altmann et al. 2024): Vergleich des APOE ϵ 4 SHAP-Rangs in frühstufigen Konvertern (Basisstufe A-T-) mit späteren Stufenwandlern (Basisstufe A+T-). Rangiert APOE in der frühen Umstellung höher? Dokumentieren Sie dies als vorgegebene sekundäre Analyse.
77. Erstellen Sie eine zusammengeführte ADNI-Datensatzdatei und 50 Patienten-Wasserfalldiagramme für AD-B.
78. Optional: Validierung der Ergebnisse mit Proteomics zweitem Feature-Set: ADNI-Plasmaproteomik (Olink-Panel), verfügbar in einer Teilmenge (~500 Teilnehmer). Erwartete konkordante Proteine: GFAP, NfL, YKL-40 (CHI3L1, Neuroinflammationsmarker).

METHODEN

- **Fehlende Daten:** *Liquor ist für ~60 % der ADNI-Teilnehmer verfügbar. Nach vollständiger CSF-Filterung und 36-monatiger Nachbeobachtung ist mit $n \sim 500-700$ zu rechnen. Dokumentiere n bei jedem Einschlussschritt.*
- **Klassenbilanz:** *Erwarten Sie ~150–200 Wandler und ~250–350 stabile MCI. Verwenden Sie `class_weight='ausgeglichen'` in allen Klassifikatoren. Berichte die Klassenverteilung auf Papier.*
- **Batch-Korrektur:** *ADNI verwendet mehrere Prüfplattformen über verschiedene Phasen hinweg (ADNI-1, ADNI-GO, ADNI-2, ADNI-3). Verwenden Sie ADNI-standardisierte Biomarker-Werte (uplift-adjusted), wo verfügbar. Wenn nicht, wende die ComBat-by-ADNI-Phase auf dem Trainingsset an. Rückfall: Mittelwert pro ADNI-Phase, Sensitivitätsanalyse mit und ohne Bericht.*
- **SHAP:** *TreeExplainer für RF. Globale Zusammenfassung + recall@k. Lokaler Wasserfall für 50 richtige Vorhersagen.*

LIEFERERGEBNISSE

- ADNIMERGE abgeleiteter merged dataset mit Umwandlungslabels, fehlendem Bericht und MICE-Imputationsprotokoll.
- SHAP recall@k Tabelle mit APOE ϵ 4 Rang explizit angegeben.
- Stufenabhängiger APOE ϵ 4 SHAP-Rangvergleich (frühe vs. späte Konverter).
- 50 Patienten-Wasserfalldiagramme für AD-B.

Tier	Ausstattung	Begründung
1	APOE ϵ 4-Genotyp	Dominanter genetischer Risikofaktor für spät einsetzende AD; OR ~3–4 für Heterozygot, ~15–25 für Homozygot. Muss die Top-3-SHAP-Funktion sein – Ausfall zeigt auf Vorverarbeitungsfehler hin.
1	Liquor-Verhältnis A β 42 oder A β 42/40	Erster ATN-Biomarker, der abnormal wurde; Stärkster Prädiktor für die Akkumulation und Umwandlung von Amyloiden
1	CSF p-tau181	Tau-Pathologiemarker; Abnorm vor dem kognitiven Abbau; zentral für das ATN-Framework

2	Plasma NfL (Neurofilamentlicht)	Neurodegenerationsmarker; erhöht in Wandlern; zunehmend als zugänglicher Bluttest verwendet
2	Plasma-GFAP	Astrozytischer Aktivierungsmarker; assoziiert mit Amyloidlast und APOE ε4-Status (Stevenson-Hoare 2022)
2	Hippocampales Volumen	Neurodegenerationsbiomarker; etablierter struktureller MRT-Marker für das Umwandlungsrisiko
3	MMSE / ADAS-Cog-Score	Kognitive Messungen, die prodromale AD widerspiegeln; Es wird erwartet, dass sie erscheinen, aber stromabwärts von den molekularen Veränderungen erfolgen

Vorbereitung als Supervisor für den AD-Track

Reichen Sie die ADNI-Bewerbung JETZT ein – bevor Sie einen Studenten rekrutieren. Die Bearbeitung dauert 2 Wochen.

Vorab ADNIMERGE: Überprüfen Sie, ob alle Tabellen sich verbinden. Die DXSUM-Tabelle definiert Umwandlungslabls.

Vorzähl-Konverter vs. stabile MCI mit deinen Einschlusskriterien vor der Vergabe der These.

Überprüfen Sie die Verfügbarkeit der ADNI-Plasma-Olink-Proteomik (Proteomik-Teilmenge, ~500 Teilnehmer).

Der stufenabhängige CEL-Test (Altmann et al. 2024) muss in der Dissertationsbeschreibung vorgegeben sein.

AD-B

ADNI + Olink-Proteomik

Quantenkernel-Methoden und Feature-Interaktionsanalyse für den Fortschreiten der Alzheimer-Krankheit

BSc/MSc

BSc/MSc · 5–6 Monate

QML für MCI-Konversion und klinische Plausibilitätsanalyse

FORSCHUNGSFRAGE

Erreicht ein Quantenklassifikator für die MCI-zu-AD-Umwandlung eine Leistung innerhalb des 95%-KI des klassischen ML – und zeigen seine SHAP-Erklärungen eine andere Merkmalsbedeutung für die APOE ε4 × ATN-Biomarker-Interaktionsstruktur im Vergleich zur klassischen ML, wie sie durch globale recall@k und die klinische Plausibilitätsanalyse bewertet werden?

ZIELE

79. Implementierung von QSVM und VQC auf einem vorverarbeiteten AD-A-Datensatz. Feature-Eingabe: Top-20 aus AD-A SHAP, mit obligatorischer Aufnahme des APOE ε4-Genotyps unabhängig vom Rang (Tier 1 CEL – wenn es in den Rängen 21–30 erscheint, explizit angeben; bei Rang 30 ausschließen und als Befund dokumentieren).
80. Schau dir das Performance Gate an. Mit ADNI n~500–700 ist dies ein echter Test der QML-Skalierbarkeit – Dokumentlaufzeit für die Berechnung von Kernel-Matrixen.
81. Wenden Sie SHAP an. Vergleiche es mit AD-A SHAP, das RBO verwendet. Spezifischer sekundärer Test: Zeigt QML SHAP eine höhere kombinierte Bedeutung für das APOE ε4 × Aβ42-Paar als für das klassische SHAP (im Einklang mit der bekannten nichtlinearen Beziehung, bei der APOE ε4 die Amyloidakkumulation antreibt)?

82. Klinische Plausibilitätsanalyse: 50 Patienten-Wasserfalldiagramme aus AD-A, abgeglichen mit QML-Äquivalenten. Klassifiziere Überraschungen. Ein Bad Surprise-Beispiel, auf das man achten sollte: Alter als Haupttreiber (das Alter korreliert mit allem in ADNI – es sollte in einem altersadjustierten Modell nicht über APOE $\epsilon 4$ und ATN-Biomarkern dominieren).
83. Proteomics zweites Merkmal: ADNI-Plasma-Olink (~500 Teilnehmer). Trainiere QSVM an Olink-Merkmalen (Top-15 nach Varianz; Plasma NfL und GFAP als CEL-Proteine behalten). Wenden Sie SHAP an. Konkordanztafel mit transkriptomik-äquivalenter SHAP.

LIEFERERERGEBNISSE

- Performance Gate-Bericht mit Laufzeitdokumentation für die Kernelmatrix $n \sim 600$.
- SHAP recall@k Vergleich: RF vs QSVM vs VQC.
- APOE $\epsilon 4 \times A\beta 42$ SHAP-Interaktionsanalyse.
- Klinische Plausibilitätsanalyse: 50-Patienten-Vergleichstabelle mit alters-als-Überraschungs-Flagging.
- Proteomik-Konkordanztafel: Olink SHAP vs. klinisches Merkmal-SHAP. Erwartete konkordante Proteine: GFAP, NfL, YKL-40 (CHI3L1, Neuroinflammationsmarker).

Betreuer-Notizen für AD-B

Mit $n \sim 600$ dauert die Berechnung der Kernel-Matrix ~ 36 Minuten für 8 Qubits (vor dem Benchmark). APOE $\epsilon 4 \times A\beta 42$ Wechselwirkungstest: Verwendung von Shap. TreeExplainer SHAP-Interaktionswerte auf RF als

klassische Referenz. Vergleichen Sie den Vorzeichen- und Ausmaßsterm der Wechselwirkung mit dem QML-Äquivalent.

Alter als schlechte Überraschung: Die Teilnehmer der ADNI sind ältere Erwachsene (55–90); Alter korreliert mit allem.

Wenn das Alter bei vielen Patienten der Hauptfaktor für SHAP ist, deutet dies darauf hin, dass das Modell sich nicht anpasst

Angemessen für das Alter – ein methodisches Problem, kein interessantes klinisches Befund.

AD-C

ADNI-
Längsschnitt

Zeitliches Quantenmaschinelles Lernen zur Modellierung longitudinaler Biomarker-Trajektorien bei Alzheimer

MSc

MSc · 6 Monate

FORSCHUNGSFRAGE

Sagt eine temporale Quantenkernel-Methode (modifizierte IQP-Merkmalsskizze, die mehrfache Zeitpunkt-Biomarkersequenzen kodiert, nach Demidik et al. 2025) die MCI-zu-AD-Umwandlung genauer voraus als statische QML und klassische LSTM – und spiegeln die temporalen SHAP-Attributionen die bekannte ATN-Biomarker-Kaskade ($A\beta$ -Änderungen vor Tau-Änderungen) korrekt wider?

ZIELE

84. Konstruiere longitudinale ADNI-Teilmenge: Teilnehmer mit ≥ 3 Besuchen (Ausgangsbefund, 12 Monate, 24 Monate) und CSF verfügbar bei ≥ 2 Besuchen. Erwarten Sie $n \sim 250\text{--}350$.

85. Implementiere Demidik et al. 2025 modifizierte IQP-Zeitmerkmalekarte in PennyLane. Kodiere [A β 42_t1, A β 42_t2, A β 42_t3, p-tau_t1, p-tau_t2, p-tau_t3, NfL_t1, NfL_t2, NfL_t3] als Quantenzustandsbewahrende temporale Ordnung.
86. Vergleiche: statisches QSVM (AD-B-Stil), LSTM (Keras, 2-Schicht), lineares Mixed-Effects-Modell, temporales QML. Primäre Kennzahl: AUC-ROC mit 95 % KI auf Hold-out-Testset.
87. Temporaler SHAP: Behandle jeden (Biomarker, Zeitpunkt) als separaten SHAP-Input. Erstellen Sie eine 2D-Heatmap (mit $\times$ Zeitpunkten). Vorgegebene Validierung: A β 42-Änderungen zu frühen Zeitpunkten sollten eine höhere SHAP-Bedeutung haben als Tau-Änderungen zu frühen Zeitpunkten – im Einklang mit der ATN-Kaskade.
88. Klinische Plausibilitätsanalyse angepasst an zeitliche Umgebungen: Entspricht bei 30 Patienten der primäre temporale SHAP-Treiber (höchstes Merkmal $\times$ Zeitpunktkombination) der erwarteten ATN-Kaskadensequenz?

METHODEN

- **Temporale Codierung:** *Modifizierter IQP mit verschränkten Gattern zwischen gleichen, zeitgleichen Qubitpaaren mit unterschiedlichen Zeitpunkten. Jeder Biomarker zu jedem Zeitpunkt = 1 Qubit. 9 Merkmale $\times$ 3 Zeitpunkte = 27 Qubits. Dies erfordert eine sorgfältige Schaltungsplanung – zuerst ein Vortest auf der Maschine des Vorgesetzten.*
- **LSTM-Basislinie:** *Keras LSTM (Einheiten=32), Dropout=0,2, Adam lr=0,001. Eingabeform: (3 Zeitpunkte, 9 Features). Binäre Ausgabe. 5-facher Lebenslauf.*
- **Rückfallplan:** *Wenn 27-Qubit-temporale QML im Simulator rechentechnisch unerreichbar ist (>8 Stunden pro Durchlauf), reduzieren Sie auf 6 Qubits (2 Biomarker $\times$ 3 Zeitpunkte) und dokumentieren Sie die Einschränkung.*

LIEFERERGEBNISSE

- Longitudinale ADNI-Pipeline (reproduzierbar, wiederverwendbar für PD-C).
- Temporale QML PennyLane-Implementierung (Open Source – geteilt mit PD-C-Student).
- Leistungsvergleich: temporale QML vs. LSTM vs. statische QML bei MCI-Umrechnung.
- 2D-zeitliche SHAP-Heatmap mit ATN-Kaskadenausrichtungsanalyse.
- Temporale klinische Plausibilitätsanalyse (30 Patienten).

Supervisor-Notizen für AD-C

Eine 27-Qubit-Schaltung ist ehrgeizig. Vorab auf deinem Server ausführen, bevor du es zuweise – default.qubit mit 27

Qubits benötigen $2^{27} = 134\text{M}$ komplexe Amplituden (~2 GB RAM pro Schaltungsauswertung).

Rückfall auf 12 Qubits (4 Biomarker $\times$ 3 Zeitpunkte), wenn der Speicher begrenzt ist.

Das Demidik et al. Paper 2025: Überprüfen Sie, ob Autoren Code veröffentlicht haben. Wenn ja, haben Sie einen Schüler

Anpassen, statt neu umzusetzen. Wenn nein, planen Sie 4–6 Wochen für die Umsetzung ein.

Teile den temporalen QML-Code mit dem PD-C-Studenten nach Abschluss – direkte Wiederverwendung.

Krankheitsspur 3: Parkinson-Krankheit

Datensatz: PPMI (CSF Alpha-Synuklein + Plasma NfL + DaTscan SBR + MoCA + UPDRS-III + GBA1 Trägerstatus + LRRK2 Trägerstatus). Zugang: ppmi-info.org (kostenlos, Registrierung ~2 Wochen).

Klassifikationsaufgabe: schnelle motorische Progressoren vs. langsame motorische Progressoren bei PD — Vorhersagen, welche Patienten über 24 Monate einen Anstieg von UPDRS-III >10 Punkte zeigen werden. Der GBA1-Trägerstatus ist ein Merkmal, kein Label.

Ground-Truth-genetische Marker

89. **LRRK2 G2019S (12q12)**: Die häufigste pathogene Variante für PD; wurde bei ~2,4 % der PD-Patienten insgesamt gefunden, bis zu 41 % bei nordafrikanischen Berber- und aschkenasischen jüdischen Populationen. Aktives therapeutisches Ziel (LRRK2-Kinaseinhibitoren in Phase-2/3-Studien). Klinischer Phänotyp ist nicht von sporadischer PD zu unterscheiden.
90. **GBA1 (1q22) — Glucocerebrosidase-Varianten**: Häufigster genetischer Risikofaktor für PD (~7,7 % der PD-Patienten tragen GBA1-Varianten). Verbunden mit schnellerem Fortschreiten, kognitivem Abbau und Lewy-Körper-Pathologie. Enzymersatz- und Substratreduktionstherapien befinden sich in Studien.
91. **SNCA (4q22) — Alpha-Synuklein**: Das erste entdeckte PD-Gen (1997); Duplikationen/Triplicationen verursachen familiäre PD; häufige SNPs am Locus modulieren das sporadische PD-Risiko. rs356182 ist das wichtigste GWAS-Signal (Simón-Sánchez et al. 2009). Alpha-Synuklein-Proteinaggregate sind die bestimmende Pathologie.
92. **PRKN, PINK1, DJ-1 (PARK7)**: Rezessive Gene, die früh einsetzende PD über mitochondriale Qualitätskontrollwege verursachen; gut validiert, aber seltener.
93. **Liquor-/Plasma-Biomarker**: Alpha-Synuklein, Neurofilamentlicht (NfL), Dopaminmetaboliten (HVA), lysosomale Enzyme (GCase-Aktivität für GBA1-Träger). Dies sind die grundlegenden Grundwahrheiten für jedes klinische Vorhersagemodell.

Wegweisende Arbeiten

94. [Polymeropoulos et al. \(1997\) — Mutation in SNCA in familiärer Parkinson-Krankheit](#) Science, ~5.000 Zitate. Die ursprüngliche Entdeckung eines PD-verursachenden Gens. Gründungspapier.
95. Simón-Sánchez et al. (2009) — GWAS offenbart genetische Risiken zugrunde liegende PD Nature Genetics, 1.899 Zitate. Identifizierte SNCA und MAPT als die beiden stärksten Loci mit gemeinsamen Varianten. Definiert die GWAS-Grundwahrheit für sporadische PD.
96. Cook et al. (2024) — PD GENERation: genetische Variantenerkennung bei 10.510 PD-Patienten Gehirn, 47 Zitate. Größte prospektive PD-Genetteststudie; 13 % Ertrag; GBA1 7,7 %, LRRK2 2,4 %. Definiert realistische Vorwahrscheinlichkeiten für jede Variante.
97. Dulski et al. (2024) — Genetik der Parkinson-Krankheit: modernste Neurologie und Neurochirurgie. Aktuelle klinische Genetik-Übersicht; Deckt GWAS, 90 Loci, NGS-Tests ab. Verwenden Sie sie als Referenz für die Grundwahrheit.

Datensätze

Datensatz	Inhalt	Zugang	Anmerkungen
-----------	--------	--------	-------------

PPMI (Parkinson-Progressionsmarker-Initiative)	1.400+ Teilnehmer · Longitudinale Liquenstoffbiomarker, Plasma, DaTscan-Bildgebung, Genetik (LRRK2, GBA1, SNCA), kognitive/motorische Bewertungen · Mehrere Zeitpunkte	ppmi-info.org – kostenlos, Registrierung erforderlich	Das Alzheimer-ADNI-Äquivalent für PD. Ausgezeichnete Längsstruktur. LRRK2- und GBA1-Genotypisierung verfügbar. Der wichtigste PD-Datensatz für deine Zwecke.
GP2 (Globales Parkinson-Genetikprogramm)	Multi-Ahnen-GWAS-Datensatz; 39.000 PD-Fälle + 1,3 Millionen Kontrollen in 100+ Ländern; Vollständige Genotypisierung	gp2.org – Bewerbung erforderlich	Größter PD-Genetik-Datensatz. GWAS-Zusammenfassungsstatistiken öffentlich verfügbar. Zugang auf individueller Ebene über die Anwendung.
GEO (PD-Transkriptomik)	Mehrere PD-Genexpressionsdatensätze; z. B. GSE7621 (substantia nigra), GSE20141 (Blut)	ncbi.nlm.nih.gov/geo – kostenlos	Blutbasierte transkriptomische Datensätze sind am relevantesten für die Entdeckung nicht-invasiver Biomarker. Suche in GEO nach 'Parkinson blood expression'.

PD-A PPMI	Prädiktive Modellierung und erklärbare KI zur Identifizierung des schnellen motorischen Fortschreitens bei Parkinson	BSc BSc · 4–5 Monate
---------------------	---	--------------------------------

Klassische ML-Basislinie für die Vorhersage des PD-Motorischen Fortschreitens

FORSCHUNGSFRAGE

Welche klinischen und genetischen Biomarkermerkmale identifiziert das klassische ML als am ehesten prädiktive für den schnellen motorischen Fortschreiten bei PPMI, und stellt die SHAP-Attribution den GBA1-Trägerstatus, das Ausgangs-MoCA und Plasma-NfL als primäre Treiber zurück – im Einklang mit dem bekannten klinischen Phänotyp von GBA1-PD?

ZIELE

98. Greifen Sie auf PPMI zu. Der Vorgesetzte stellt vorgefertigte Datensätze bereit (siehe Vorbereitungscheckliste). Definiere Progressionslabels: fast = UPDRS-III-Veränderung >10 nach 24 Monaten; langsam = UPDRS-III-Änderung <3. Patienten mit intermediärer Veränderung (3–10) aus der Primäranalyse ausschließen – Dokument n ausgeschlossen.
99. Merkmale: GBA1-Trägerstatus (binär 0/1), LRRK2-Trägerstatus (binär 0/1), CSF-Alpha-Synuklein, Plasma NfL, DaTscan SBR (laut DATSCAN_SBRANALY Tabelle), MoCA, UPDRS-III-Ausgangswert, Alter, Geschlecht, Krankheitsdauer, Ausbildungsjahre. Standardisieren Sie genetische binäre Merkmale NICHT.
100. Train RF und SVM-RBF. Wenden Sie SHAP an. Vorgegebene Prüfung: GBA1 muss in den Top 10 der SHAP-Funktionen für eine schnelle Fortschrittsvorhersage erscheinen. LRRK2 sollte eine negative SHAP-Richtung haben (LRRK2-PD schreitet langsamer voran).

101. Untergruppenanalyse: innerhalb von GBA1-Trägern, innerhalb von LRRK2-Trägern, innerhalb idiopathischer PD – berechnet man separate SHAP-Ranglisten. Unterscheidet sich das Merkmals-Wichtigkeitsmuster je nach genetischer Untergruppe?
102. Erstellen Sie vorverarbeitete Datensätze und 50 Patienten-Wasserfalldiagramme für PD-B.
103. Optional: Ergebnisse mit Proteomics verifizieren. Zweiter Funktionssatz: PPMI-Plasmaproteomik, verfügbar in einer Teilmenge. Erwartete konkordante Proteine: NfL-Protein (Simoa-Test), GFAP, totale Alpha-Synuklein-Oligomere.

METHODEN

- **PPMI-Datenzusammenführung:** Der Vorgesetzte stellt vorgefertigte CSV aus PPMI-Tabellen bereit: BIOSPECIMEN (CSF), VITAL (Plasma NfL, falls verfügbar), DATSCAN_SBRANALY, UPDRS, MoCA, DEMOGRAFIE GENETIC_TESTING. Studierende sollten die 50-PPMI-Tabellen nicht allein bedienen.
- **Klassengrößen:** Erwarte ~150–250 schnelle Progressoren und ~150–200 langsame Progressoren. Wenn unausgeglichen, verwenden Sie `class_weight='ausgeglichen'`.
- **Fehlendes DaTscan:** Nicht alle Teilnehmer haben bei jedem Besuch DaTscan. Verwenden Sie Baseline-DaTscan, wo verfügbar; Dokument N fehlt. DaTscan nicht zuschreiben – ausschließen und als Sensibilitätsanalyse berichten.

LIEFERERERGEBNISSE

- Zusammengeführter PPMI-Datensatz mit Progressionslabels und genetischen Untergruppen-Flaggen.
- SHAP recall@k mit GBA1-Rang und LRRK2-Richtung explizit dokumentiert.
- Untergruppen-SHAP-Vergleich (GBA1 vs. LRRK2 vs. idiopathisch).
- 50 Patienten-Wasserfalldiagramme für PD-B.

Tier	Ausstattung	Begründung
1	GBA1-Carrier-Status	Stärkster genetischer Prädiktor für ein schnelles Fortschreiten von PD; GBA1-PD weist einen 2–3× schnelleren motorischen und kognitiven Abbau auf als idiopathische PD. Muss für die Vorhersage des schnellen Fortschreitens als wichtig erscheinen.
1	Baseline MoCA-Ergebnis	Kognitive Beeinträchtigung zu Beginn sagt eine schnellere Gesamtentwicklung voraus; GBA1-PD zeigt eine frühe kognitive Beteiligung
1	Plasma NfL	Neurodegenerationsmarker; erhöhter NfL zu Beginn prognostiziert eine schnellere Progression der PPMI
2	Liquor-Alpha-Synuklein	In einigen Studien ist ein niedrigerer Liquor-Alpha-Syn mit höherer Lewy-Körper-Belastung und schnellerem Rückgang verbunden
2	DaTscan SBR (striatale Bindungsverhältnisse)	Niedrigere dopaminerge Integrität zum Ausgangspunkt in Verbindung mit schnellerem motorischen Fortschreiten

3	LRRK2-Trägerstatus (negative Richtung)	LRRK2-PD ist mit einem langsameren Fortschreiten verbunden; Erwartet wird ein negativer SHAP-Wert für die Fast-Progressor-Klasse
---	--	--

Vorbereitung des Betreuers für den PD-Track

Reichen Sie den PPMI-Antrag JETZT zusammen mit ADNI ein. Bearbeitung ~2 Wochen.

Treten Sie selbst PPMI-Tabellen vor – bieten Sie dem Studierenden eine einzige zusammengeführte CSV an.

Das ist nicht optional: PPMI hat ~50 Tische und die Studierenden werden Wochen damit verschwenden, sie zu navigieren.

Zähle schnelle vs. langsame Progressoren vorab mit deinem UPDRS-Schwellenwert, bevor du es zuteilst.

Überprüfen Sie den verfügbaren Status GBA1 und LRRK2 für ausreichend n (erwarten Sie ~20 % GBA1, ~10 % LRRK2 in PPMI).

PD-B
PPMI

Bewertung von Quantenklassifikatoren und Signalweg-Feature-Interaktionen im Fortschreiten der Parkinson-Krankheit

BSc/MSc
BSc/MSc · 5–6 Monate

QML für PD-Fortschreitung und klinische Plausibilitätsanalyse

FORSCHUNGSFRAGE

Erreicht ein Quantenklassifikator für PD-motorische Progression eine Leistung innerhalb des 95%-KI des klassischen ML – und zeigt seine SHAP-Erklärung für die schnelle Progressionsprognose eine höhere kombinierte Bedeutung für das GBA1- $\times$ CSF-Alpha-Synuklein-Merkmal-Paar (das die lysosomale Signalweg-Interaktion widerspiegelt) im Vergleich zu klassischer SHAP, was auf die Erfassung einer Wechselwirkungsstruktur auf Pfadebene hindeutet?

Der GBA1-Mangel verursacht die Alpha-Synuklein-Akkumulation über den lysosomalen Weg – eine mehrstufige nichtlineare Beziehung, die ein Quantenkern, der paarweise Interaktionen codiert, besser erfassen sollte als ein klassisches lineares Modell. Wenn QML-SHAP für dieses Merkmalspaar eine höhere kombinierte Bedeutung zeigt als das klassische SHAP, ist das der mechanistisch motivierte QML-Vorteilsbehauptung.

ZIELE

104. Implementierung von QSVM und VQC auf einem PD-A-Datensatz. Feature-Input: Top-20 von PD-A SHAP. GBA1-Trägerstatus: unabhängig vom Rang einschließen, wenn er von 21 bis 30 fällt; Schließen Sie es aus, wenn Sie unter 30 sind, und dokumentieren Sie.
105. Schau dir das Performance Gate an. Hinweis: PPMI n ist kleiner als ADNI (~300–450 nach Filterung nutzbar). Erwarten Sie breitere CIs.
106. Primärer Interaktionstest: Berechnung des SHAP-Interaktionswerts für (GBA1, CSF Alpha-Synuklein) Paar sowohl in klassischem RF als auch QSVM. Die Hypothese des lysosomalen Weges: GBA1-Mangel $\rightarrow$ Scheitern der lysosomalen Clearance $\rightarrow$ Alpha-Synuklein-Akkumulation ist eine nichtlineare mehrstufige Beziehung. Ein Quantenkern mit paarweisen Termen KANN diese Wechselwirkung expliziter erfassen als ein klassischer Kernel – das testen wir, nicht annehmen.
107. Klinische Plausibilitätsanalyse: 50 Patienten-Wasserfalldiagramme. Schlechte Überraschung zu beobachten: Die Krankheitsdauer ist der Haupttreiber (die Krankheitsdauer

korreliert mit der motorischen Schwere der Motorik, ist aber nicht der ursächliche Faktor für die Fortschrittsrate – ein Modell, das darauf setzt, erfasst phänotypische Korrelationen, nicht biologische Mechanismen).

108. Hinweis zur Proteomik: Wenn PPMI-Plasma-Proteomikdaten für Ihre Kohorte verfügbar sind, wenden Sie QSVM auf Proteinmerkmale an und erstellen Sie eine Konkordanztafel. Falls nicht verfügbar, dokumentiere Abwesenheit und mach ohne weiter.

LIEFERERGEBNISSE

- Leistungs-Gate-Bericht.
- GBA1 × Alpha-Synuklein-SHAP-Interaktionsvergleich (RF vs. QSVM).
- Klinische Plausibilitätsanalyse mit Krankheitsdauer-Bad Surprise-Flagging.
- Proteomik-Konkordanztafel, falls Daten verfügbar sind.

Betreuernotizen für PD-B

Der GBA1 × Alpha-Synuklein-Interaktionstest ist die Hauptbehauptung – bereiten Sie den Schüler vor um den Mechanismus des lysosomalen Weges zu artikulieren, bevor sie ein Modell ausführen.

SHAP-Interaktionswerte: Verwende `Shap.TreeExplainer(model).shap_interaction_values(X)` für RF.

Für QSVM verwenden Sie paarweise KernelExplainer-Störungen. Dokumentiere den Unterschied in der Methode.

Wenn PPMI-Plasmaproteomik nicht verfügbar ist: Beachten Sie dies als Einschränkung; Nicht zuschreiben oder ersetzen.

PD-C

PPMI
Längsschnitt

Zeitliche Quantenmodelle für longitudinale Biomarker- und kognitive Abbausequenzen bei Parkinson

MSc

MSc · 6 Monate

FORSCHUNGSFRAGE

Verbessert das in AD-C entwickelte temporale QML-Framework die Vorhersage des motorischen und kognitiven Rückgangs bei PD im 24. Monat, wenn es auf longitudinale PPMI-Biomarker-Trajektorien angewendet wird – und spiegeln die temporalen SHAP-Attributionen die bekannte Sequenz der PD-Biomarker-Veränderungen wider (Alpha-Synuklein → dopaminergen Verlust → kognitiven Abbau)?

ZIELE

109. Konstruktive longitudinale PPMI-Teilmenge: ≥3 Besuche mit konsistenter Biomarker-Messung. Regressionsziele: UPDRS-III mit 24 Monaten und MoCA nach 24 Monaten (zwei separate Modelle).
110. Wiederverwenden Sie die temporale QML PennyLane-Implementierung aus AD-C. Kodiere [Alpha-syn_t1, Alpha-syn_t2, NfL_t1, NfL_t2, DaTscan_t1, DaTscan_t2, MoCA_t1, MoCA_t2] als temporalen Quantenzustand.

111. Vergleiche: temporales QML, LSTM, statisches QML, lineares Mixed-Effects-Modell. Primäre Kennzahl: MAE und Pearson R auf Hold-out-Test-Set für kontinuierliche Progressionspunkte.
112. Temporale SHAP-Heatmap. Vorgegebene ATN-analoge Prüfung: DaTscan-Änderungen (dopaminergem Verlust) sollten zu früheren Zeitpunkten von großer Bedeutung sein; MoCA-Veränderungen sollten zu späteren Zeitpunkten eine hohe Bedeutung haben – sie spiegeln die bekannte Entwicklung vom motorischen zum kognitiven Bereich wider.

Supervisor-Notizen für PD-C

Temporales QML-Code stammt aus AD-C. Rekrutiere PD-C zwei Monate nach AD-C, um die Implementierungsübergabe zu ermöglichen.

Regression (kontinuierliche UPDRS-Vorhersage) statt Klassifikation bedeutet, dass SHAP-Werte Einheiten der beigetragenen UPDRS-Punkte – klinisch leichter zu interpretieren als Wahrscheinlichkeitsbeiträge.

Longitudinaler Liquor ist nur für eine Teilmenge von PPMI (~300) verfügbar. Prüfe n vorab vor der Zuweisung.

Krankheitsspur 4: Darmkrebs

Datensatz: TCGA-COAD + TCGA-READ zusammengeführt (mRNA FPKM-UQ + Methylierung + somatische Mutationsaufrufe einschließlich KRAS, BRAF, APC als binäre Merkmale). CMS-Labels: Guinney et al. 2015 (unabhängig von der Expression abgeleitet, nicht nur aus Mutationsaufrufen).

Klassifikationsaufgabe: CMS1 (MSI-immun, BRAF-angereichert) vs. CMS4 (mesenchymal, schlechteste Prognose). Dies sind die beiden biologisch am stärksten unterschiedlichen CMS-Subtypen. Die CMS-Subtypisierung erfordert derzeit vollständige Transkriptomik – das ist in allen Zentren nicht routinemäßig. Prognose und neue Behandlungsentscheidungen unterscheiden sich erheblich.

Ground-Truth-genetische Marker

113. **APC (5q22):** Mutiert in ~80 % der sporadischen Darmkrebse; das auslösende Ereignis in der Adenom-Karzinom-Sequenz. Keimlinien-APC-Mutationen verursachen familiäre adenomatöse Polyposie (FAP) mit nahezu 100 % CRC-Durchdringung.
114. **KRAS (12p12):** Mutiert in ~40 % des CRC; wichtiger Pfad: RAS-RAF-MEK-ERK. Der KRAS-Mutationsstatus bestimmt direkt die Eignung für eine Anti-EGFR-Therapie (Cetuximab, Panitumumab) – eines der klarsten Beispiele für handlungsfähige genomische Biomarker.
115. **MLH1, MSH2, MSH6, PMS2 — MMR-Gene:** Keimbahnmutationen verursachen das Lynch-Syndrom (erbliches CRC); somatisches Silencing verursacht Mikrosatelliteninstabilität (MSI-H) bei ~15 % der sporadischen CRC. Der MSI-H-Status ist nun ein von der FDA zugelassener Biomarker für die Pembrolizumab-Immuntherapie – ein äußerst gut validiertes binäres Klassifikationsziel.
116. **BRAF V600E:** Mutiert in ~10 % des CRC; starker prognostischer Marker und therapeutisches Ziel. Nahezu gegenseitig ausschließend mit KRAS-Mutationen – ein Gen-Gen-Interaktionsmuster, das Ihr QML-Modell erfassen sollte.

Wegweisende Arbeiten

117. [Fearon & Vogelstein \(1990\) — Ein genetisches Modell für die kolorektale Tumorentstehung](#) Zelle, ~12.000 Strafzettel. Das ursprüngliche APC/KRAS/TP53-Mutationssequenzmodell. Grundlegende Referenz.
118. [Cancer Genome Atlas Network \(2012\) — Umfassende molekulare Charakterisierung menschlichen Darm- und Rektalkrebses](#) Nature, ~6.000 Zitationen. Die TCGA-COAD/READ-Zeitung. Definiert die vier CMS-Subtypen und die vollständige Treibermutationslandschaft. Unverzichtbare Referenz für jede TCGA-CRC-Studie.

Mögliche Datensätze

Datensatz	Inhalt	Zugang	Anmerkungen
TCGA-COAD + TCGA-READ	~620 Tumore · mRNA, miRNA, Methylierung, somatische Mutationen, CNA · MSI-Status kommentiert	portal.gdc.cancer.gov – kostenlos	Der gut annotierte MSI-Status macht die binäre Klassifikationsaufgabe sehr sauber. KRAS- und BRAF-Mutationsaufrufe verfügbar.

GEO GSE39582	566 CRC-Tumoren · Genexpression · MSI-Status · Überleben · Kohorte der unabhängigen Validierung	ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE39582 – kostenlos	Eine der am häufigsten verwendeten externen Validierungskohorten für CRC-Genexpressionsstudien. Gut zum Testen der QML-Generalisierbarkeit.
--------------	---	---	---

CRC-A TCGA-COAD/READ	Erklärbare Multi-Omics-Klassifikation und Mutationsinteraktionswiederherstellung für Kolorektalkrebs-Subtypen	BSc BSc · 4–5 Monate
--------------------------------	--	--------------------------------

Klassische ML-Basislinie für die CMS1- vs. CMS4-Klassifikation

FORSCHUNGSFRAGE

Welche Multi-Omics-Merkmale identifiziert die klassische ML als am diskriminierendsten für die CMS1- vs. CMS4-Subtyp-Subtypisierung von Kolorektalkrebs, und stellt die SHAP-Attribution die vordefinierten CEL-Merkmale – BRAF V600E, Immuninfiltrationsmarker (CD8A, GZMB), EMT-Marker (ZEB1, VIM) – korrekt fest und erfasst sie die gegenseitige Exklusivität von KRAS/BRAF als negativen SHAP-Interaktionswert?

ZIELE

119. Laden Sie TCGA-COAD + TCGA-READ über TCGAblinks herunter. Merge (ähnliche Biologie; erhöht n). Laden Sie CMS-Etiketten aus dem Guinney 2015 Supplement oder dem CMSclassifier R-Paket herunter. Beschränke dich nur auf CMS1- und CMS4-Samples.
120. Merkmale: mRNA Top-2000 nach Varianz (behalten Sie alle Tier-1/2 CEL-Gene) + Methylierung M-Werte Top-500 + binäre Mutationsmatrix für KRAS, BRAF, APC, TP53, SMAD4. KRAS und BRAF sind Merkmale, keine Etiketten.
121. Train RF und SVM-RBF. Wenden Sie SHAP an. CEL-Wiederherstellungsscheck: BRAF muss in den Top-20 für CMS1 erscheinen; CD8A/GZMB muss erscheinen; ZEB1/VIM muss für CMS4 (positive SHAP-Richtung) erscheinen.
122. KRAS/BRAF-Gegenseitigkeits-Exklusivitätstest: Berechnung des SHAP-Interaktionswerts für das (KRAS, BRAF)-Paar. Erwartet: negativer Wechselwirkungswert (wenn BRAF=1, trägt KRAS weniger bei). Dokumentieren Sie den vorgegebenen Test.
123. Erstellen Sie vorverarbeitete Datensätze und 50 Patienten-Wasserfalldiagramme für CRC-B.
124. Optional: Ergebnisse mit Proteomikdaten überprüfen (siehe CRC-B)

METHODEN

- **CMS-Label-Hinweis:** CMS-Labels aus Guinney 2015 stammen aus Expressionsmustern, nicht aus dem Mutationsstatus – deshalb ist die Aufnahme von KRAS/BRAF als Merkmale nicht-zirkulär. Der Subtyp ist nicht durch eine einzelne Mutation definiert.
- **Zusammengeführte Kohorte:** COAD + READ: ~620 Stichproben insgesamt. CMS1 ~20%, CMS4 ~23% aller CRC – erwarten Sie nach dem Filtern ~120 CMS1 und ~140 CMS4.

- **Batch-Korrektur:** COAD und READ sind separate Sequenzierungschargen. Trage ComBat nach Tumorstelle (Dickdarm vs. Rektum) auf dem Trainingsset an. Rückfall: Mittelmittelpunkt pro Standort. Sensitivitätsanalyse mit und ohne.

LIEFERERGEBNISSE

- Zusammengeführter TCGA-CRC-Datensatz mit CMS1/CMS4-Labels.
- SHAP recall@k mit BRAF-Rang und explizit angegebenem KRAS/BRAF-Interaktionswert.
- 50 Patienten-Wasserfalldiagramme für CRC-B.

Tier	Ausstattung	Begründung
1	BRAF V600E-Mutation (CMS1)	CMS1 ist stark angereichert für BRAF V600E und MSI-H; Die BRAF-Mutation ist ein nahezu definierendes Merkmal dieses Subtyps
1	CD8A, GZMB, PRF1 (CMS1)	Zytotoxische T-Zellsignatur, die CMS1 immunentzündeten Phänotyp definiert; gegründet in Guinney 2015
1	ZEB1, VIM, CDH2 (CMS4)	EMT-Marker (epithelial-mesenchymaler Übergang) definieren den CMS4-mesenchymalen Phänotyp
2	KRAS-Mutation (fehlt in CMS1, vorhanden in CMS2/3 — negativ für CMS1)	KRAS und BRAF schließen sich nahezu gegenseitig aus; SHAP sollte BRAF-positiv und KRAS negativ für CMS1 zeigen
2	MLH1-Methylierung (CMS1)	MSI-H in CMS1 wird in sporadischen Fällen durch MLH1-Promotormethylierung verursacht; wird voraussichtlich für CMS1 erscheinen
3	TGFB1, FN1 (CMS4)	TGF- β -Weg und Fibronektin — stromale/mesenchymale Treiber, die für CMS4 charakteristisch sind

Vorbereitung des Betreuers für den CRC-Track

Laden Sie sofort die ergänzenden CMS-Aufgaben von Guinney 2015 herunter.

Führen Sie das CMSclassifier R-Paket auf Ihren TCGA-Daten aus, um zu überprüfen, ob CMS-Labels übereinstimmen.

Vorverifiziere KRAS- und BRAF-Mutationsfrequenzen in deinem zusammengeführten Datensatz: KRAS ~40%, BRAF ~10%,

Nebenwirkung <2 %. Bestätigen Sie die gegenseitige Exklusivität, bevor Sie CRC-A zuweisen.

Der KRAS/BRAF-Interaktionstest muss im Thesis Exposee vorgegeben sein.

CRC-B
TCGA-
COAD/READ

Quantenklassifikationsmodelle und explizite Gen-Gen-Interaktions-Wiederherstellung in der Kolorektalkrebs-Subtypisierung

BSc/MSc
BSc/MSc · 5–6 Monate

QML für die CMS-Subtypklassifikation und Gen-Gen-Interaktionswiederherstellung

FORSCHUNGSFRAGE

Erreicht ein Quantenklassifikator für CMS1 vs. CMS4 eine Leistung innerhalb des 95%-CI des klassischen ML – und stellt der ZZFeatureMap-Quantenkernel, der explizit paarweise Feature-Produkte kodiert, die KRAS/BRAF-Exklusivität als negatives Wechselwirkungssignal klarer zurück als ein klassischer RBF-Kernel?

ZIELE

125. Implementierung von QSVM und VQC auf dem CRC-A-Datensatz. Feature-Eingabe: Top-18 mRNA-Features aus CRC-A SHAP + KRAS-Binärform + BRAF-Binärform = insgesamt 20 Features. KRAS und BRAF sind Pflichtaufnahmen, unabhängig vom SHAP-Rang (sie sind die Funktionen des Interaktionstests).
126. Schau dir das Performance Gate an.
127. Primärer Interaktionstest: Berechnung der SHAP-Interaktionswerte für (KRAS, BRAF) Paar in RF und QSVM. Primärhypothese: QSVM, dessen ZZFeatureMap ZZ-Rotationstermen enthält, die $x_i \cdot x_j$ -Produkte kodieren, sollte die negative KRAS-BRAF-Wechselwirkung mindestens ebenso klar erfassen wie RF. Dokumentieren Sie, dass dies ein empirischer Test und keine angenommene Eigenschaft ist.
128. Klinische Plausibilitätsanalyse: 50 Patienten-Wasserfalldiagramme. Für CMS1-Patienten sollte der primäre Treiber immunbezogene Merkmale sein (CD8A, GZMB, BRAF). Bei CMS4-Patienten sollte der Haupttreiber mesenchymale Merkmale (ZEB1, VIM, TGFB1) sein. Eine schlechte Überraschung: Sequenzierungs-Qualitätsmetriken oder Stichprobenerhebungsvariablen erscheinen als Haupttreiber.
129. Hinweis zur Proteomik: TCGA liefert RPPA für ~200 CRC-Proben. Beziehen Sie ein, wenn Überschneidungen mit CMS1/CMS4-Proben ausreichend sind (>80). Erwartete konkordante Proteine: Phospho-MAPK (BRAF-Weg für CMS1), Vimentinprotein (EMT für CMS4).

LIEFERERERGEBNISSE

- Leistungs-Gate-Bericht.
- KRAS/BRAF-Interaktionswertvergleich: RF vs. QSVM (Hauptergebnis).
- Klinische Plausibilitätsanalyse mit subtypspezifischer Erwartungsprüfung.
- RPPA-Konkordanztafel (falls n ausreichend).

Betreuernotizen für CRC-B

Die Interaktion zwischen KRAS/BRAF ist die wissenschaftliche Geschichte dieser These. Stellen Sie sicher, dass der Schüler das versteht
die Biologie vor dem Ausführen eines Modells: KRAS und BRAF aktivieren denselben MAPK-Pfad und sind daher funktional redundant – Mutationen in der einen machen Mutationen im anderen überflüssig. Diese biologische gegenseitige Exklusivität sollte sich als negative statistische Wechselwirkung manifestieren.
Wenn QSVM dies wiederherstellt und der klassische RBF nicht – ist das klar, mechanistisch motiviert
Ergebnis für die Behauptung des Quantenvorteils.
RPPA-Probenüberlappung: TCGA RPPA ist für ~200 CRC-Proben verfügbar. Überschneidung mit CMS1/CMS4 prüfen
bevor die Proteomik-Analyse zugewiesen wird.

FORSCHUNGSFRAGE

Bewahren Quantenkerne, die durch ZZFeatureMap und IQP induziert werden, die bekannte biologische Clusterstruktur von CMS1/CMS4 besser als klassische Kernel – und ist ein Qualitätsvorteil speziell auf die verschränkte Komponente der Merkmalskarte zurückzuführen, wie sie durch den Vergleich verschränkter vs. nicht-verschränkter Kernmatrizen getestet wurde?

Hinweis: Diese Arbeit verwendet echte biologische Datensätze (TCGA-COAD/READ) und einen taxonomischen Kontrolldatensatz (UCI Codon Usage). Alle Quantenschaltkreisberechnungen werden auf einem klassischen Simulator (PennyLane default.qubit) durchgeführt – keine Quantenhardware ist erforderlich.

ZIELE

130. Kontrollexperiment zuerst (verpflichtend): Implementierung einer Kernel-Qualitätsbewertungspipeline auf dem UCI-Codon-Nutzungsdatensatz (13.028 Organismen, 64 Codon-Nutzungsfrequenzmerkmale, Reich/Phylum/Klasse/Ordnungslabes). Überprüfen Sie, ob Quantenkerne ARI anhand von Reichsetiketten vergleichbar mit klassischem RBF produzieren, bevor Sie Krebsdaten berühren.
131. Berechnen Sie Quantenkernel-Matrizen für ZZFeatureMap reps=1, ZZFeatureMap reps=2, IQP, hardware-effizienter Ansatz (nur Ry, kein Verschränkung – dient als Nullmodell), zufälliges unitäres (zufälliges Nullmodell). Eingabe: Top-8 mRNA-Features von CRC-A SHAP.
132. Berechnen Sie klassische Kerne: RBF, Polynom, linear. Bewerten Sie alle mit CMS1/CMS4-Labels unter Verwendung von ARI, NMI, Kernel Target Alignment. Statistische Signifikanz: Permutationstest (CMS-Labels 1000 Mal mischen).
133. Ablation: Vergleiche ZZFeatureMap mit hardware-effizient (gleiche Parameter, kein Verschränkung). Delta ARI wird der Verschränkung zugeschrieben. Dies ist das Hauptergebnis.
134. Kernel-PCA-Visualisierung (2D) gefärbt nach CMS-Subtyp – nur unterstützende Beweise, kein primäres Ergebnis.
135. Verbindung zu CRC-B: Vergleichen Sie, welche Merkmale die Kerengeometrie (höchster Kernelbeitrag pro Feature) antreiben, zu welchen Merkmalen SHAP in CRC-B wichtig ist. Konkordanzanalyse auf demselben TCGA-CRC-Datensatz.

METHODEN

- **UCI-Codon-Nutzungskontrolle:** Download von archive.ics.uci.edu/dataset/577/codon+usage. Keine Anmeldung. 64 Merkmale, 13.028 Organismen. Verwenden Sie Kingdom-Level-Labels (5 Klassen) zur Kontrollvalidierung.
- **Kernel-Berechnung:** `pennylane.kernels.kernel_matrix()` für die Batch-Auswertung. Alle Quantenschaltungsberechnungen auf dem PennyLane default.qubit-Simulator.

- **Stichprobengröße:** Verwenden Sie $n=200$ Teilstichproben von TCGA-CRC für die Kernel-Berechnung (n^2 Evaluationen = 40.000 Schaltkreise; Pre-Benchmark-Laufzeit bei ~10 ms/Schaltung = insgesamt ~7 Minuten).
- **Cluster-Metriken:** `sklearn.metrics: adjusted_rand_score, normalized_mutual_info_score`. Kernel Target Alignment: benutzerdefinierte Implementierung nach Cortes et al. 2012.

LIEFERERGERBNISSE

- Kontrollvalidierungsergebnisse (UCI-Codon-Nutzung – Pipeline, verifiziert vor der Krebsanalyse).
- Vergleichstabelle der Kernel-Qualität: Alle Merkmalsabbildungen × ARI/NMI/KTA mit permutationstestenden p-Werten.
- Ablationsergebnis: delta-ARI-verschränkt vs. nicht-verschränkt (primäres Ergebnis).
- Kernel-PCA-Visualisierungen (unterstützend).
- CRC-B-Konkordanzanalyse: Kerngeometrie-Merkmale vs. SHAP-Wichtige Merkmale.

Betreuer-Notizen für CRC-C

Führen Sie die UCI Codon Usage-Kernel-Pipeline selbst vor: 200 Beispiele × 8 Features × ZZFeatureMap
Dauert ~7 Minuten bei default.qubit. Dies ist die Rechenvalidierung, bevor der Schüler beginnt.

Die Ablation (verschränkt vs. nicht verheddernd) ist der wissenschaftliche Beitrag – sicherstellen Sie den Schüler

versteht, dass die beiden Schaltungen identische Anzahl trainierbarer Parameter haben müssen.

Negative Ergebnisrahmung: Wenn ZZFeatureMap ARI nicht besser als RBF ist, ist das eine veröffentlichungsfähige Erkenntnis.

Bereite diese Rahmung gemeinsam mit dem Studierenden vor, damit sich ein Nullergebnis nicht wie ein Scheitern der Abschlussarbeit anfühlt.

Krankheitsspur 5: Typ-2-Diabetes (Pilotstudien + Stichprobeneffizienz)

Datensatz: GEO-Islet-Transkriptomik (GSE25724 + GSE15932 + GSE41762 kombiniert mit ComBat-Batch-Korrektur). n~120–160 nach der Zusammenführung. Dies ist eine echte klinische Einschränkung aus einer kleinen Stichprobe.

WICHTIGE RAHMUNG: T2D-A, T2D-B sind PILOTSTUDIEN. Ihre individuellen SHAP-Befunde sind vorläufig aufgrund des kleinen n und müssen mit Vorsicht interpretiert werden. T2D-D (Probeneffizienz) ist der WICHTIGSTE wissenschaftliche Beitrag dieses Studiengangs. Stellen Sie T2D-A/B/C nicht als endgültige Biomarker-Entdeckungsartikel vor.

Klassifikationsaufgabe: Insel-Transkriptomik von prädiabetischen Spendern (HbA1c 5,7–6,4 %, beeinträchtigte Glukosetoleranz) vs. normoglykämische Spender. Klinisch motiviert: Prädiabetes ist das Zeitfenster zur Prävention; Molekulare Veränderungen der Insel gehen der klinischen Diagnose voraus.

Ground-Truth-genetische Marker

136. **TCF7L2 rs7903146 (10q25.2):** Die wirkungsvollste einzelne genetische Risikovariante für T2D. T-Allel-Träger haben ein erhöhtes Risiko von 1,45× (heterozygot) bis 2,41× (homozygot) (Grant et al. 2006). Mechanismus: beeinträchtigte Insulinsekretion von Betazellen über Wnt/GLP-1-Signalübertragung. Repliziert in >100 unabhängigen Kohorten aller wichtigen ethnischen Gruppen.
137. **KCNJ11 (Kir6.2), ABCC8 (SUR1):** Betazell-ATP-empfindliche K⁺-Kanaluntereinheiten. Varianten, die sowohl mit Typ-2D- als auch mit neonatalem Diabetes verbunden sind – starkes mechanistisches Verständnis, gute sekundäre Wahrheit.
138. **PPARG Pro12Ala:** Das Ala-Allel schützt gegen T2D (~0,8× Risiko). PPARG ist das Ziel von Thiazolidinedion-Medikamenten – eines der besten Beispiele, bei denen eine GWAS-Variante direkt das Zielgebiet des Medikaments informiert.
139. **HNF1A, HNF4A:** Monogene MODY-Gene (Maturity-Onset Diabetes of the Young), die ebenfalls häufige Risikovarianten für T2D tragen – wichtig, da die Fehlklassifikation von MODY vs. T2D ein echtes klinisches Problem darstellt, bei dem eine korrekte Merkmalsidentifikation direkten Patientenvorteil bringt.
140. **Klinische Biomarker:** HbA1c, Nüchtern glukose, HOMA-IR, HOMA-B, BMI, Taillenumfang – gut etablierte klinische Merkmale, die in jeder glaubwürdigen Merkmalsbedeutungsbewertung auftreten müssen. Das TCF7L2-Risikoallel ist mit einem niedrigeren BMI und einer geringeren Insulinsekretion verbunden (Hansen et al. 2025) – eine nicht offensichtliche Wechselwirkung, die Ihr QML-Modell idealerweise wiederherstellen sollte.

Wegweisende Arbeiten

141. Grant et al. (2006) — Variante des TCF7L2-Gens verleiht das Risiko für Typ-2-Diabetes *Nature Genetics*, 2.302 Zitate. Das ursprüngliche Entdeckungspapier. Das wichtigste Zitat für die T2D-Genetik.
142. Lyssenko et al. (2007) — Mechanismen, durch die TCF7L2-Varianten das T2D-Risiko erhöhen *Journal of Clinical Investigation*, 830 Zitationen. Mechanistische Arbeit, die TCF7L2 mit einer beeinträchtigten Insulinsekretion und Inkretineffekten verknüpft – definiert die biologische Interpretation der Variante.

143. [Mahajan et al. \(2018\) — Fein-Mapping von Typ-2-Diabetes-Loci auf Einzelvarianten-Auflösung](#) Nature Genetics, ~1.000 Zitationen. Bisher größte T2D-GWAS-Feinkartierung; identifiziert 403-Signale über 276 Loci. Bietet die vollständige genetische Architektur, die dein Modell teilweise wiederherstellen sollte.
144. del Bosque-Plata et al. (2021) — Die Rolle von TCF7L2 bei Typ-2-Diabetes-Diabetes, 128 Zitate. Umfassende mechanistische Überprüfung; nützlich zur Validierung der biologischen Interpretation von QML-Feature-Rankings.

Datensätze

Datensatz	Inhalt	Zugang	Anmerkungen
GEO GSE15932 / GSE25724 (Inselgenexpression), GSE41762?	Pankreasinsel-Transkriptomik · T2D vs. normale Spender · Genexpression + TCF7L2-Expressionsdaten	ncbi.nlm.nih.gov/geo – kostenlos	Kleiner, aber direkt relevant für TCF7L2-expressionsbasierte Analysen. Handhabbare Größe für QML-Simulatorstudien.

T2D-A GEO-Insel (Pilot)	Erklärbares maschinelles Lernen zur Prädiabetes-Klassifikation mittels Transkriptomik mit kleinen Stichproben von Inseln	BSc BSc · 4 Monate
--------------------------------------	---	------------------------------

Klassischer ML-Pilot: Prädiabetes vs. normale Insel-Transkriptomik

FORSCHUNGSFRAGE

In einem Transkriptomik-Datensatz für die Pankreasinsel (n~120) kann klassische ML (RF, SVM) Prädiabetiker von normoglykämischen Spendern klassifizieren – und zeigen SHAP-Attributionen erhöhte TCF7L2-Expression und beeinträchtigte Insulinsekretionsweg-Gene, die mit vordefiniertem CEL übereinstimmen? (Pilotstudie: Bootstrap-KI zu SHAP-Werten erwartet breit zu sein; die Ergebnisse bilden Hypothesen.)

ZIELE

145. Laden Sie GEO GSE25724, GSE15932 GSE41762 über das GEOquery R-Paket herunter. Zusammenführen mit ComBat-Batch-Korrektur (nur Fit on Training Set). Rückfall, falls ComBat bei kleinen Chargengrößen (<10 Proben/Batch) scheitert: Verwendung von Mittelmittel-Zentrierung pro Charge und Meldung der Sensitivitätsanalyse. Wenn es weiterhin instabil ist, verwenden Sie stattdessen SVA (Surrogatvariablenanalyse).
146. Trainieren Sie RF und SVM-RBF mit LOOCV (bei geringem n ist LOOCV für die Leistungsschätzung besser geeignet als fünffach). Bootstrap CIs über stratified bootstrap (500 Resamples).
147. Wenden Sie SHAP an. Berichte CEL-recall@k mit Bootstrap-CIs zu SHAP-Werten (wichtig: Quantifiziere SHAP-Instabilität bei dieser Stichprobengröße). Visualisieren Sie SHAP-Wertvarianz über Bootstrap-Resamples für Top-10-Features – dies fließt direkt in die XAI-Stabilitätsanalyse von T2D-D ein.
148. Erstellen Sie vorverarbeitete Datensätze und SHAP-Stabilitätsanalysen für T2D-B und T2D-D.

METHODEN

- **Batch-Korrekturprotokoll:** (1) ComBat am Trainingsset. (2) Wenn ComBat fehlschlägt (singuläre Matrix, $<10/\text{Batch}$): Mittelmittelzentrum pro Charge. (3) Falls weiterhin problematisch: SVA (sva R Package). (4) Ergebnisse immer mit und ohne Batch-Korrektur als Sensitivitätsanalyse zu melden.
- **SHAP-Stabilität:** Für jede der 500 Bootstrap-Resamples werden die Top-10-SHAP-Features berechnet. Berichte über Rang-Konsistenz (Kendalls W über Resamples hinweg). Dies quantifiziert, wie instabil Feature-Rankings bei $n \sim 96$ Trainingsproben sind.

LIEFERERGERBNISSE

- Zusammengeführter batchkorrigierter Inseldatensatz mit Batch-Korrektur-Entscheidungsprotokoll.
- LOOCV-Leistung mit Bootstrap CI.
- SHAP recall@k mit Bootstrap CI – Pilotergebnisse, die eindeutig als vorläufig gekennzeichnet sind.
- SHAP-Rangstabilitätsanalyse (Kendalls W) – direkte Eingabe für T2D-D.

Betreuer-Notizen für T2D-A

Das ist ausdrücklich ein Pilotprojekt. Erlaube NICHT, dass der Schüler SHAP-Ergebnisse überinterpretiert. Die SHAP-Stabilitätsanalyse ist ebenso wichtig wie die Ergebnisse der CEL-Wiederherstellung. Wenn Kendalls W niedrig ist (z. B. $<0,3$), sind SHAP-Rankings bei diesem n unzuverlässig. Diese Entdeckung motiviert T2D-D – die Feature-Rankings sind bei $n \sim 70$ instabil, also was ist das Mindestens n bei dem sie stabilisieren? Das ist die Frage von T2D-D. Batch-Korrektur-Fehlermodus: Mit 3 GEO-Datensätzen ist mit Chargengrößenproblemen zu rechnen. Bereiten Sie sich vor die SVA-Rückfalloption vor der Zuweisung.

T2D-B
GEO-Insel
(Pilot)

**Bewertung des quantenmechanischen Lernens
und der Erklärbarkeitsstabilität in der
Transkriptomik von kleinen Stichproben auf
Inseln**

BSc/MSc
BSc/MSc · 5 Monate

QML Pilot: Implementierung und SHAP-Vergleich auf Small Islet-Datensatz

FORSCHUNGSFRAGE

Erreicht ein Quantenklassifikator (QSVM) in einem Islet-Transkriptomik-Datensatz mit kleiner Stichprobe eine Leistung innerhalb des 95%-KI des klassischen ML – und sind seine SHAP-Erklärungen mehr oder weniger stabil (Kendalls W über Bootstrap-Resamples) als klassische SHAP-Attributionen, was Pilotbelege für die XAI-Zuverlässigkeit von QML im Low- n -Regime liefert?

ZIELE

149. Implementierung von QSVM auf einem T2D-A vorverarbeiteten Datensatz. Feature-Input: Top-10 von T2D-A SHAP (reduziert von 20 bei sehr geringem n – weniger Features

verringern das Überfitting-Risiko). TCF7L2-Ausdruck: einschließen, wenn die Ränge 11–15 stehen; Dokumentieren.

150. Performance Gate: Mit $n \sim 96$ Trainingsproben erwarten Sie breite CIs. Es wird nicht erwartet, dass QML bei diesem n besser abschneidet als klassisch – die Lernkurve in T2D-D adressiert dies direkt. Dokumentiere die Leistung als Kontext.
151. SHAP-Stabilitätsvergleich: Berechnung der SHAP-Rangstabilität (Kendalls W) für QSVM über dieselben 500 Bootstrap-Resamples wie T2D-A. Vergleiche $W(\text{QML})$ mit W (klassisch). Vorgegebene Frage: Ist die QML-SHAP-Stabilität höher oder niedriger als die klassische SHAP-Stabilität bei $n \sim 96$?
152. Klinische Plausibilitätsanalyse: 20 Patienten (reduziert von 50 bei einem kleinen Testset). Klassifiziere Überraschungen.

LIEFERERGERBNISSE

- QSVM-Leistung mit 95 % KI – kontextualisiert als Pilot.
- SHAP-Stabilitätsvergleich: $W(\text{QML})$ vs $W(\text{klassisch})$ — primäres Ergebnis dieser These.
- Klinische Plausibilitätsanalyse (20 Patienten, klar als Pilotbeweis gekennzeichnet).

Supervisor-Notizen für T2D-B

Der SHAP-Stabilitätsvergleich IST der Beitrag. Formulieren Sie das nicht als 'findet QML bessere Biomarker?'.

Stellen Sie es so ein: 'Sind QML-Erklärungen bei sehr kleinem n stabiler oder weniger stabil als klassische?'

Dies fließt direkt in das XAI-Stabilitätsexperiment von T2D-D ein und ist unabhängig von der Richtung eine neuartige Entdeckung.

Mit $n \sim 96$ Trainingsproben kann QML das klassische ML unterlegen – das ist zu erwarten und in Ordnung. Das Performance Gate zeigt wahrscheinlich überlappende CIs, anstatt dass QML besser performt.

T2D-C

Synthetisch +
GEO

Quantifizierung der Erklärbarkeitstreue im quantenmechanischen maschinellen Lernen: Die Auswirkungen der Merkmalkodierung auf die Gen-Gen-Interaktions-Erholung bei Typ-2-Diabetes

MSc

MSc · 6 Monate

Forschungsfrage

Sind SHAP-Merkmal-Wichtigkeitsrankings für Quantenklassifikatoren den zugrunde liegenden Modellentscheidungen für Daten mit eingepflanzter Gen-Gen-Interaktionsstruktur (die TCF7L2-KCNJ11-Koregulation nachahmen) treu, oder verzerrt die Wahl der Quantenfeature-Codierung systematisch die Attribution?

Ziele

153. Entwerfen und implementieren Sie das systematische synthetische Interaktionsexperiment: Pflanzen-XOR-, AND- und lineare Wechselwirkungssignale

zwischen Merkmalenpaaren; Bewertung der SHAP-Treue für QSVM mit 3 verschiedenen Merkmalskarten

154. Definieren und messen Sie die SHAP-Treue formal: Verwenden Sie Ground-Truth-Merkmalsmasken, um die Genauigkeit/Abruf der SHAP-Attribution im Vergleich zum geplanten Signal zu berechnen
155. Erkenntnisse auf reale T2D-Inseldaten anwenden: Welche Codierung erzeugt die biologisch konsistentesten Attributionen?
156. Erstellen Sie ein verallgemeinerbares Treuebewertungssystem, das über alle Krankheitspfade hinweg wiederverwendbar ist

Methoden & Werkzeuge

157. Synthetisches Design: $n=1000$ Proben; $p=50$ Merkmale; Anlage (a) lineares Signal in Merkmal 1, (b) XOR-Wechselwirkung in Merkmalen 2+3, (c) UND Wechselwirkung in Merkmal 4+5; Alle anderen Merkmale Rauschen
158. SHAP-Treuheitsmetrik: Für geplanten Signaltyp berechnet SHAP recall@k (welcher Anteil der besten SHAP-Merkmale werden geplant?); Lauf für $k=1,2,\dots,10$
159. Wiederholen: RF (Baseline), QSVM-ZZFeatureMap, QSVM-IQP, VQC-StrongEntangling; Handlung recall@k Kurven
160. Nullmodell: Mischlabels; Überprüfen Sie SHAP recall@k Drops an Chance
161. Anwendung realer Daten: Anwendung der Gewinncodierung auf GEO-Inseldaten; TCF7L2-Rangverbesserung melden

Lieferergebnisse

162. Faithfulness Evaluation Framework als eigenständiges Python-Paket (pip-installable; Open Source)
163. Recall@k Kurven über alle Modelle und Interaktionstypen hinweg (Hauptfigur für das Papier)
164. Fazit: Für welchen Interaktionstyp übertrifft QSVM RF in SHAP-Treue?
165. Kodierungsempfehlung für Typ-2-Diabetes (und als Leitfaden für andere Krankheitsrichtungen)

Voraussetzungen (Student)

166. Starker Python; Solide Statistik (verstehen, was SHAP berechnet, nicht nur, wie man es ausführt)
167. QML auf Intermediate-Niveau; T2D-B-Pipeline verfügbar
168. Lesen Sie Lundberg & Lee 2017 (SHAP-Artikel), bevor Sie beginnen

Anmerkung des Betreuers

Der Treuerahmen ist das primäre, veröffentlichungsfähige Ergebnis – es ist verallgemeinerbar und geht direkt auf das klinische XAI-Problem ein, das du identifiziert hast (ist SHAP für QML vertrauenswürdig?).

Diese Dissertation bildet die methodische Grundlage für die horizontale Arbeit, die alle Krankheitsspuren vereint.

Ermutigen Sie den Studenten, das Framework von Anfang an als Python-Paket zu schreiben, nicht als Notizbuch.

Das synthetische Experiment ist das Kernergebnis der Arbeit. Die Anwendung von Realdaten ist unterstützende Beweise.

T2D-D

GEO-Insel +
TCGA-BRCA-
Unterstichprob
e

Empirische Bewertung der Effizienz und der Erklärbarkeitsstabilität von quantenmechanischem maschinellem Lernen in klinischen Datensätzen mit niedriger Stichproben

MSc

MSc · 6 Monate

FORSCHUNGSFRAGE

Bei welcher Trainingsset-Größe erhält QML (QSVM, VQC) eine angemessene Klassifikationsleistung und stabile CEL-angepasste SHAP-Attributionen, während klassisches ML (RF, SVM) sich verschlechtert – und ist dieser Crossover-Punkt konsistent über einen authentischen klinischen Datensatz (T2D-Inselchen, $n \sim 120$) und künstlich heruntergemusterte große Datensätze (TCGA-BRCA subsampled auf $n=60, 100, 150, 200$)?

WISSENSCHAFTLICHE GRUNDLAGE

Caro et al. (2022, Nature Communications) bewiesen QML-Generalisierungsfehlerskalen als $\sqrt{(T/N)}$ – was impliziert, dass QML besser verallgemeinert als klassisches ML, wenn die Trainingsgröße N im Verhältnis zur Anzahl trainierbarer Parameter klein ist. T. Belis et al. (2021) zeigten empirische Unterstützung in der physikalischen Klassifikation. Diese Dissertation liefert den ersten Test in klinischen biomedizinischen Daten.

ZIELE

169. Lernkurvenexperiment auf T2D-Inseldaten: Trainieren Sie QML und klassisches ML auf zunehmend größeren Zufalls-Teilmengen: $n = 10, 20, 30, 40, 50, 60, 70, 80, 100$ % des Trainingssets (8 Größen). Bewerten Sie bei jeder Größe das feste Testset. Berichte AUC-ROC mit 95 % Bootstrap-KI. Wiederhole das 10-mal pro Trainingsgröße (verschiedene Zufallsstichproben). Berichtsmittelwert ± 95 % KI.
170. Crossover-Punkt-Identifikation: die Trainingsset-Größe N^* , unterhalb der QML 95%-KI liegt über oder überlappt mit dem klassischen ML-CI, und oberhalb dessen konvergieren die Kurven. Dies ist das primäre quantitative Ergebnis.
171. XAI-Stabilität entlang der Lernkurve: Bei jeder Trainingssatzgröße berechnet man die SHAP-Rangstabilität (Kendalls W über 10 Resamples). Melde $W(\text{QML})$ und $W(\text{klassisch})$ als Funktion von N . Vorgegebene Frage: Hält QML eine höhere SHAP-Stabilität als klassisches ML bei kleinem N ?
172. SMOTE-Übersampling-Experiment: Anwendung von SMOTE, um das Trainingsset künstlich von $n \sim 70$ auf $n=150, 200, 300$ zu erweitern. Beeinflusst synthetische Augmentation die QML- vs. klassische Leistungs-Crossover? Verbessert es die Stabilität von SHAP?

173. TCGA-BRCA-Replikation: Verwenden Sie BC-B-trainierte Modelle. Teilstichprobe TCGA-BRCA-Trainingssets auf $n=60, 100, 150, 200, 300, 500$ (wobei der vollständige Testsatz konstant bleibt). Führe ein Lernkurven-Experiment durch. Zeigen QML und klassische Kurven das gleiche Crossover-Muster wie T2D? Falls ja: Das Ergebnis verallgemeinert sich. Wenn nein: Das T2D-Ergebnis ist datensatzspezifisch, was ebenfalls informativ ist.

METHODEN

- **Lernkurve:** *sklearn.model_selection.learning_curve* mit einem benutzerdefinierten QML-Schätzer-Wrapper. Stellen Sie sicher, dass der Testsatz NIEMALS in die Subsampling einbezogen wird.
- **SMOTE:** *imblearn.over_sampling.SMATTE*. Bewerben Sie sich nur innerhalb der Trainings-Folds. Vergleiche SHAP-Stabilität mit SMOTE und ohne. Testset nicht übersampeln.
- **TCGA-BRCA-Zugriff:** Erfordert BC-B-Modelle und BC-B vorverarbeitete Datensätze. Koordiniere dich mit der BC-Streckenzeit.
- **Statistischer Test:** An jedem Lernkurvenpunkt wird geprüft, ob QML und klassische CI sich überlappen oder getrennt sind. Berichte als primärer Befund genau N^* , wo sie abweichen.

LIEFERERGEBNISSE

- Lernkurvendiagramme: AUC vs. Trainingsset-Größe für QML und klassische (T2D-Inselchen).
- XAI-Stabilitätslernkurve: Kendalls W vs N für QML und klassisch.
- SMOTE-Experiment: Leistung und Stabilität mit und ohne Augmentation.
- TCGA-BRCA-Replikationslernkurven – passen QML/klassische Crossover-Muster überein?
- N^* -Schätzung mit Konfidenzintervall (Bootstrap) – das Schlagzeilen-Veröffentlichungsergebnis.

Betreuernotizen für T2D-D

Dies ist die wertvollste Abschlussarbeit im T2D-Bereich und eine der am besten publizierbaren im Projekt. Das theoretische Ergebnis von Caro et al. 2022 verleiht ihm eine solide Grundlage – zitiere explizit in der Einleitung.

TCGA-BRCA-Koordination: Der T2D-D-Schüler benötigt die vorverarbeiteten Daten und trainierten Modelle von BC-B.

Sequenz: BC-B sollte 3+ Monate vor der TCGA-Replikationsphase von T2D-D liegen.

N^* -Konfidenzintervall: Bootstrap, indem du das Experiment mit der vollständigen Lernkurve 100 Mal durchführst

Mit verschiedenen zufälligen Samen. Melde Median N^* und 90 % KI über die Läufe hinweg.

Wenn QML KEINEN Small-n-Vorteil zeigt: Melde das ehrlich. Sie widerspricht der Theorie im klinischen Bereich – das als negatives Ergebnis mit wichtigen Implikationen veröffentlicht werden kann.

Krankheitsspur 6: Rheumatoide Arthritis

Datensatz: GEO-Synovialtranskriptomik (GSE55235 + GSE82107 + GSE77298 kombiniert). n~200–300 Synovialgewebeproben nach dem Verschmelzen. Proteomics zweiter Funktionssatz: Mun et al. 2021 Serum LC-MS/MS (RA vs. gesund, AGT/SAA4/VDBP/RBP4 validiert).

Klassifikationsaufgabe: RA-Synovialgewebe vs. OA-Synovialgewebe. Klinisch motiviert: Die Unterscheidung zwischen früher seronegativer RA und OA ist eine echte diagnostische Herausforderung, die zu 2–3-jährigen Diagnoseverzögerungen führt. Die Grundwahrheit liegt auf Weg-Ebene (entzündliche Zytokine vs. degenerative Wege) – die Genotypisierung einzelner genetischer Varianten (HLA, PTPN22) ist in diesen Datensätzen nicht verfügbar.

RA-A GEO-Synovial	Erklärbarkeit auf Signalwegniveau in der transkriptomischen Klassifikation von rheumatoider versus Arthrose	BSc BSc · 4–5 Monate
-----------------------------	--	--------------------------------

Klassische ML-Basislinie für RA- vs. OA-Synovialklassifikation

FORSCHUNGSFRAGE

Welche synovialen Genexpressionsmerkmale identifiziert die klassische ML als am meisten diskriminierend für RA vs. OA, und stellt die SHAP-Attribution das vordefinierte Signalwegniveau-CEL – pro-inflammatorische Zytokine (IL6, TNF, IL1B), T-Zell-Infiltrationsmarker (CXCL10, CXCL13, CD3D) und JAK-STAT-Signalweggene – zurück, während mesenchymale/degenerative Merkmale (PPARG, MMP13) als CML-gerichtet oder negativ zugeordnet angezeigt werden?

WICHTIGER HINWEIS ZUR WAHRHEIT VOR ORT

Pfadebene statt genebene Bodenwahrheit

Im Gegensatz zu Brustkrebs (BRCA1/2-Mutation als individuelles Genmerkmal) oder Alzheimer (APOE ε4 als

individuelle genetische Variante), validiert dieser Track auf Pfadebene.

HLA-DRB1- und PTPN22-Genotypisierung ist in GEO-Synovialdatensätzen nicht verfügbar.

Die Grundwahrheit ist: Stellt SHAP das bekannte RA- vs. OA-Transkriptionsprogramm wieder her?

Recall@k wird anhand der Zytokinweg-Gene und T-Zellmarker (CEL Tier 1/2) bewertet,

nicht gegen einzelne kausale SNPs. Das ist eine gültige, aber weniger spezifische Bestätigung.

Erkenne diese Einschränkung ausdrücklich in der Dissertation und in der Arbeit an.

ZIELE

174. Laden Sie GEO GSE55235 herunter (40 Proben: 10 RA + 10 OA + 10 normal), GSE82107 (34 Proben: 18 RA + 16 OA), GSE77298 (26 Proben: 16 RA + 10 OA). Fusion mit ComBat (fit on training set). Beschränke dich auf RA vs. OA (ohne normales Gewebe für binäre Klassifikation). Insgesamt erwartet n: ~90–120 RA + ~80–100 OA.
175. Train RF und SVM-RBF. LOOCV (mit moderatem n, Ergänzung mit 5-fachem CV). Wenden Sie SHAP an. CEL recall@k Check: IL6, TNF, CXCL10, CXCL13, CD3D müssen in den Top-20 SHAPs für RA-Klasse erscheinen. PPARG sollte eine negative SHAP-Richtung für RA-Klasse haben.
176. Schnelle Replikation: Gleiche Pipeline auf GSE55235 Validierungsdatensatz anwenden (während des Trainings zurückgehalten).

177. Erstellen Sie vorverarbeitete Datensätze und 40 Patienten-Wasserfalldiagramme für RA-B (kleiner n bedeutet weniger Patienten).
178. Optionaler zweiter Funktionssatz von Proteomics: Mun et al. 2021 Serum LC-MS/MS-Datensatz (RA vs. gesunde Steuerung; AGT, SAA4, VDBP, RBP4 als validierte Protein-Biomarker). Hinweis: Dieser Datensatz verwendet Serum statt Synovialgewebe, daher ist der Vergleich Kreuzmodalität (Synovialexpression vs. systemische Proteomik) – dies ist eher eine Stärke als eine Begrenzung, da Konkordanz zwischen den Kompartimenten eine stärkere Biomarker-Behauptung darstellt.

METHODEN

- **Batch-Korrektur:** *Drei verschiedene GEO-Studien – sorgfältige ComBat erforderlich. Jeder GEO-Zugang = eine Charge. Mindestens 10 Proben pro Batch im Trainingsset (RA und OA getrennt). Wenn die Chargen-Einschränkung nicht erfüllt ist: Mittelmittelpunkt pro Zugang. Empfindlichkeitsanalyse ist verpflichtend.*
- **Hinweis zur Stichprobengröße:** *Nach dem Zusammenführen insgesamt n~200–220. Nach der 80/20-Aufteilung, Ausbildung Nr. 160–176. Das ist größer als T2D, aber kleiner als TCGA. Verwende 5-fache CV (nicht LOOCV), melde aber mit Bootstrap CI.*

LIEFERERERGEBNISSE

- RA/OA-Synovialdatensatz mit Batchkorrektur-Dokumentation zusammengeführt.
- SHAP recall@k Tabelle mit CEL-Bewertung auf Pfadebene.
- PPARG-Richtungsanalyse (negativer SHAP für RA-Kurs).
- 40 Patienten-Wasserfalldiagramme für RA-B.

Tier	Merkmal / Weg	Begründung
1	IL6, TNF, IL1B (pro-inflammatorisk)	Kern-RA-Entzündungszytokine; therapeutische Ziele (Tocilizumab für IL-6; Adalimumab für TNF); muss mit positivem SHAP für RA-Klasse erscheinen
1	CXCL10, CXCL13	Chemokine, die die Lymphozyteninfiltration in das Synovium antreiben; identifiziert als Hub-Gene in RA-Synovialstudien (Chen et al. 2025)
2	CD3D, CD8A, FOXP3 (T-Zell-Marker)	Die T-Zell-Infiltration ist ein pathologisches Merkmal des RA-Synoviums; in reiner OA fehlt
2	MMP1, MMP3, MMP13	Matrix-Metalloproteinasen – erhöht bei RA, was Knorpel- und Knochenabbau verursacht; Auch in OA relevant, aber das Muster unterscheidet sich
2	PPARG (negativ auf RA)	Liao et al. 2024: PPARG wurde sowohl bei RA als auch OA im Vergleich zum normalen Zustand herunterreguliert, aber das relative Ausprägungsmuster unterscheidet sich – erwartet bei negativem SHAP
3	JAK1, JAK3, STAT3	JAK-STAT-Weg – therapeutische Ziele bei RA (Baricitinib, Tofacitinib); Erwartet, dass sie RA-spezifische Signalisierung widerspiegelt

Vorbereitung des Betreuers für den RA-Track

Laden Sie GSE55235, GSE82107 GSE77298 sofort bei GEO herunter (keine Registrierung erforderlich).
 Führe vorläufige ComBat durch, um die Machbarkeit der Batch-Korrektur vor der Zuweisung zu testen.
 Die drei GEO-Datensätze haben unterschiedliche Probe-/Gen-IDs – harmonisieren vor dem Zusammenführen (Entrezgene-Kartierung).
 Überprüfen Sie, ob der Mun et al. Proteomics-Datensatz 2021 zum Download verfügbar ist. Kontaktieren Sie die Autoren
 Wenn Daten nicht ergänzend sind – werden Serumproteomik-Daten oft separat hinterlegt.

RA-B GEO-Synovial- + Serumproteomik	Quantenklassifikation und intermodalitätsbasierte proteomische Validierung rheumatoider Arthritis-Biomarker	BSc/MSc BSc/MSc · 5–6 Monate
---	--	--

QML für RA vs. OA und klinische Plausibilitätsanalyse mit Proteomik-Validierung

FORSCHUNGSFRAGE

Erreicht ein Quantenklassifikator für RA- vs. OA-Synovialklassifikation eine Leistung innerhalb des 95%-KI des klassischen ML – und zeigen seine SHAP-Erklärungen die gleiche Pathway-Level-Attribution (entzündliche vs. degenerative Genmodule), wobei konkordante Ergebnisse in einem Serum-Proteomik-Datensatz repliziert werden?

ZIELE

179. Implementierung von QSVM und VQC auf einem vorverarbeiteten RA-A-Datensatz. Feature-Eingabe: Top-20 von RA-A SHAP (alle sollen aufgrund des RA/OA-Kontrasts pathway-relevant sein).
180. Schau dir das Performance Gate an. Hinweis: RA vs. OA ist ein relativ eindeutiger biologischer Kontrast – klassisches ML kann einen AUC >0,90 erreichen. QML muss im CI liegen.
181. Wenden Sie SHAP an. Pathway-Level CEL recall@k. Vergleiche QML mit klassischen Feature-Rankings mit RBO.
182. Klinische Plausibilitätsanalyse: 40 Patienten-Wasserfalldiagramme. Für RA-Patienten sollte der Hauptauslöser die Entzündungs- bzw. Immunmerkmale sein. Bei OA-Patienten sollte der Hauptantrieb die Knorpelmatrix oder metabolische Merkmale sein. Schlechte Überraschung: Altersdominanz (sowohl RA als auch OA sind altersbedingte Krankheiten – ein Modell, das sich hauptsächlich auf das Alter stützt, ist mechanistisch nicht informativ).
183. Optional (siehe Einschränkungen unten): Proteomics zweiter Funktionsset: Mun et al. 2021 Serumproteomik. Beachten Sie, dass dies eine intermodalitätsübergreifende Validierung ist: Expression von Synovialgewebe vs. systemischen Serumproteinen. Trainieren Sie QSVM mit Proteinmerkmalen (AGT, SAA4, VDBP, RBP4 plus zusätzlich validierte RA-Serumproteine). Wenden Sie SHAP an. Konkordanzanalyse: Weisen sowohl Serum-SHAP als auch Synovial-SHAP auf eine Aktivierung des Entzündungswegs hin?
184. Hinweis zur seronegativen RA: Wenn in den GEO-Datensätzen Beispielannotationen ACPA-positiv von ACPA-negativ RA unterscheiden, vergleichen Sie SHAP-Profile zwischen Untergruppen als explorative Analyse.

LIEFERERERGEBNISSE

- Leistungs-Gate-Bericht.
- Pathway-Level SHAP recall@k und RBO-Vergleich (QML vs. klassisch).
- Klinische Plausibilitätsanalyse (40 Patienten) mit Alters-Bad Surprise-Flagging.
- Crossmodalitäts-Proteomik-Konkordanzanalyse, sofern machbar (Synovialexpression vs. Serumproteine).
- Vergleich von seronegativem und seropositivem SHAP (explorativ, falls Anmerkung vorhanden).

Supervisor-Notizen für RA-B

Die Validierung der intermodalitätsübergreifenden Proteomik ist der besondere Beitrag dieser These. Die Konkordanz zwischen Synovialgewebe-SHAP (Genexpression) und Serum-SHAP (Proteinen) liefert ein Multi-Evidenz-Fall für die identifizierten Biomarker auf Signalwegniveau.

Der Serum-Datensatz von Mun et al. verwendet RA vs. gesunde Kontrollen, nicht RA vs. OA. Erkenne das an

Unterschied — Die Proteomik-Validierung ist nicht identisch mit der Transkriptomik-Aufgabe.

Alter als schlechte Überraschung: Sowohl RA als auch OA treten bei älteren Patienten häufiger auf. Alter überprüfen

Verteilung zwischen den Gruppen in Ihrem zusammengeführten Datensatz. Wenn das Alter eine große Störung ist,

Fügen Sie das Alter als Kovariate in das Modell hinzu und dokumentieren Sie die Auswirkungen auf SHAP-Rankings.

RA-C

GEO-Synovial
+ Methylierung

**Multi-Omics-Integration und
Erklärbarkeitstreue auf Pathway-Ebene in
Modellen der rheumatoiden Arthritis**

MSc

MSc · 6 Monate

FORSCHUNGSFRAGE

Verbessert die Integration der Methylierung von Synovial-DNA mit Genexpression die QML-Klassifikation von RA vs. OA – und deuten die SHAP-Attributionen eines Multi-Omics-QML-Modells auf dieselben Merkmale des entzündlichen Weges wie bei Single-Omics-Modellen hin, was Belege liefert, dass Multi-Omics-Integration die Erklärbarkeit auf Wegebene nicht verwässert?

HINTERGRUND

RA weist eine erhebliche epigenetische Dysregulation auf: Veränderungen der DNA-Methylierung in synovialen Fibroblasten sind gut dokumentiert (insbesondere an entzündlichen Genpromotern). GEO GSE112656 liefert DNA-Methylierungsdaten für RA-Synovialfibroblasten. Die Integration von Methylierung mit Expression könnte die Klassifikation verbessern und ergänzende Biomarker-Belege liefern – oder auch nicht, was ebenfalls informativ ist.

ZIELE

185. Erhalten Sie GEO GSE112656 (RA-Synovialfibroblast-Methylierung). Identifizieren Sie Proben, die sich mit Expressionsdatensätzen aus RA-A überlappen. Die gemeinsame Multi-Omics-Analyse erfordert abgegliche Stichproben – Dokument n mit beiden Datentypen (wahrscheinlich n~60–80 abgeglichen).
186. Trainieren Sie QSVM auf: (a) nur Expression (Top-10 Merkmale), (b) nur Methylierung (Top-10 CpG-Stellen nach Varianz), (c) konkatenierte Expression + Methylierung (insgesamt 20 Merkmale). Vergleichen Sie Leistungs- und SHAP-Profile unter drei Bedingungen.
187. CEL-Signalwegüberprüfung auf Methylierungsmerkmale: Welche RA-assoziierten Promotoren sind am meisten methyliert oder demethyliert? Erwartet: IL6-Promotordemethylierung (erhöhte Expression), FOXP3-Methylierungsänderungen (T-regulatorische Zellen). Treten diese im Methylierungs-SHAP auf?
188. Multi-Omics-SHAP-Konkordanz: Deuten Expression SHAP und Methylierungs-SHAP beide auf dieselben biologischen Signalwege hin? Pathway-Anreicherungsanalyse mit MSigDB (typische Gensets) auf beiden SHAP-Top-Feature-Listen.
189. Klinische Plausibilitätsanalyse: 20 Patienten für das Multi-Omics-Modell. Erhöht oder verringert das Hinzufügen von Methylierung die Überraschungsrate im Vergleich zum Expression-only-Modell?

LIEFERERGEBNISSE

- Multi-Omics-Datensatz (abgestimmte Expression + Methylierung, n~60–80).
- Leistungsvergleich mit drei Bedingungen (nur Ausdruck, nur Methylierung, kombiniert).
- Crossmodalitäts-SHAP-Konkordanz: Anreicherung des Expressionswegs vs. Anreicherung des Methylierungswegs.
- Klinische Plausibilitätsanalyse (20 Patienten) für Multi-Omics-Modell.

Supervisor-Notizen für RA-C

Die abgestimmte Probe n (~60–80) ist klein. Diese These ist von Natur aus explorativ – erkennen Sie das an.

Die Konkordanz zur Anreicherung der Signalwege (zeigen Expression und Methylierungs-SHAP auf dieselben Signalwege?)

ist der Hauptbeitrag: Er prüft, ob die Integration von Multi-Omics die Erklärbarkeit bewahrt.

Wenn die Methylierung nichts zur Leistung beiträgt UND SHAP für Verwirrung sorgt: Das ist ein Befund.

Es legt nahe, dass für den klinischen Einsatz die Erklärung der Single-Omics sauberer ist.

Dies ist eine RA-spezifische Erkenntnis, die zur breiteren Erklärbarkeitsliteratur beiträgt.

Hilbert Space Geometry Track: Begründung und Leitprinzipien

Wie dieser Track mit den Krankheits-Tracks zusammenhängt

Der HS-Track unterscheidet sich methodisch von den Krankheits-Tracks.

Krankheitsspuren: klinische Ergebnisse klassifizieren → SHAP anwenden → klinische Plausibilität bewerten.

HS-Track: Berechnung von Quantenkern-Matrizen → Bewertung der geometrischen Clusterqualität → Ablatverschränkung.

Kein SHAP. Keine klinischen Erwartungslisten. Keine klinische Plausibilitätsanalyse. Kein Performance-Gate.

Die Bewertungsmetriken sind ARI, NMI, Kernel Target Alignment und Ablationsdelta-ARI.

Alle Quantenschaltungsberechnungen werden auf einem klassischen Simulator (PennyLane default.qubit) durchgeführt.

Echte biologische Datensätze werden überall verwendet (UCI Codon Usage, TCGA-BRCA, TCGA-COAD).

Natur und Zweck dieser Strecke

Der Geometrie-Track Hilbert Space (HS) unterscheidet sich methodisch von allen Krankheitsstrecken im Projekt. Während die Krankheitsspuren fragen, welche Merkmale für eine klinische Vorhersage relevant sind und ob SHAP-Erklärungen klinisch treu sind, stellt der HS-Track eine vorherige geometrische Frage: Bewahrt die Quantenfeature-Kodierung überhaupt die biologisch bedeutsame Ähnlichkeitsstruktur?

Dies ist eine notwendige Ergänzung zum Hauptprojekt. Das klinische XAI-Argument beruht auf einer impliziten Annahme: dass die interne Darstellung der Daten im Quantenmodell eine gewisse Beziehung zur biologischen Struktur hat und dass SHAP-Attributionen dies widerspiegeln. Der HS-Track prüft diese Annahme direkt, indem er die Geometrie der Quantenfeature-Räume – der Kernmatrizen – anhand bekannter biologischer Labels untersucht. Wenn Quantenkerne die biologische Clusterstruktur nicht erhalten, wird die theoretische Motivation für den Einsatz von QML in den Krankheitsspuren geschwächt. Falls ja, und wenn die Verschränkungskomponente verantwortlich ist, liefert dies unabhängige geometrische Belege dafür, dass QML etwas biologisch Sinnvolles tut, das über das hinausgeht, was klassische Kernel erreichen.

Kritische Terminologie: Simulator vs. Hardware vs. Datensatz

Alle Quantenschaltungsberechnungen in diesem Bereich werden auf einem klassischen Simulator durchgeführt

(PennyLane default.qubit). Es wird keine Quantenhardware benötigt oder verwendet.

Wie der HS-Track mit den Krankheits-Tracks verbunden ist

Die HS-Strecke ist nicht von den Krankheitsstrecken isoliert – sie teilt Daten und schafft die Bedingungen für das Cross-Track-Paper H4. Die Verbindungen sind:

190. **Gemeinsame Eingabefunktionen:** *HS-A verwendet die Top-8-Features aus BC-A SHAP-Ranking als Eingabe für die Berechnung des Quantenkernels. Das bedeutet, dass die geometrische Analyse und die Attributionsanalyse auf denselben Merkmalen aus demselben TCGA-BRCA-Datensatz arbeiten – was einen direkten Vergleich ermöglicht.*
191. **CRC-C als HS-Einstiegspunkt:** *Die Analyse der Kernelgeometrie für CRC (CRC-C-Dissertation in den Krankheitsspuren) verwendet dieselbe Pipeline wie HS-A für TCGA-COAD/READ-Daten. CRC-C ist sowohl eine Krankheitsspur-Thesis als auch eine Replikationsstudie für HS. Der Pipeline-Code wird geteilt.*
192. **Cross-Track Paper H4:** *Sobald HS-A und BC-B abgeschlossen sind, fragt der Cross-Track-Vergleich: Stimmen die von SHAP in BC-B (Attributionslinse) als wichtig identifizierten Merkmale mit den Merkmalen überein, die die Quanten-Kernel-Cluster-Trennung in HS-A (Geometrielinse) antreiben? Konkordanz ist konvergente Belege für die biologische Validität von QML; Dissonanz ist eine tiefere Erkenntnis zur Modellinterpretierbarkeit.*

Regelprinzipien speziell für die HS-Strecke

HS-Prinzip 1 — Zuerst Steuerungsdatensatz

Jede HS-Arbeit muss mit einem vollständigen Durchlauf der Analysepipeline des Kontrolldatensatzes beginnen, bevor biologische Daten berührt werden. Die Kontrolle validiert die Pipeline, stellt Ausgangslaufzeiten fest und liefert – entscheidend – dem Schüler ein Ergebnis, das er mit der bekannten Wahrheit überprüfen kann, bevor er schwierigere Fragen zu verrauschenden biologischen Daten stellt. Ein Studierender, der die Kontrolle überspringt und direkt zu den Krebsdaten übergeht, hat keine Grundlage zu wissen, ob seine Pipeline korrekt funktioniert.

HS-Prinzip 2 — Ablation ist der wissenschaftliche Beitrag

Zu berichten, dass 'ZZFeatureMap erreicht ARI = 0,45 bei PAM50-Untertypen' ist beschreibend, nicht wissenschaftlich. Der wissenschaftliche Beitrag ist die Ablation: der Vergleich von ZZFeatureMap (mit verschränkten CNOT/CZ-Gattern) mit der Basislinie ohne Verschränkung (identische Ry-Winkelcodierung, keine Verschränkungsgatter, gleiche Parameteranzahl). Der Zwischenfall zwischen ihnen ist speziell auf Verschränkungen zurückzuführen. Ohne diese Ablation könnte das Ergebnis vollständig durch die Winkelkodierungsstruktur erklärt werden und hat keine spezifischen Auswirkungen auf das Quantencomputing.

Ablationsschaltungsspezifikation (gilt für alle HS-Thesen)

Verschränkte Schaltung: $Ry(x_i \cdot \pi)$ auf jedem Qubit, dann CNOT-Kette zwischen benachbarten Qubits, dann $\exp(i \cdot x_i \cdot x_j \cdot ZZ)$ -Rotationen $Z \otimes Z$. Das ist ZZFeatureMap.

Nicht-verschränkte Basislinie: $Ry(x_i \cdot \pi)$ nur auf jedem Qubit. Kein CNOT. Keine ZZ-Rotation.

Beide Schaltungen müssen die gleiche Anzahl an Eingangsmerkmalen und die gleiche Anzahl an Qubits haben.

Sie unterscheiden sich nur darin, ob verschränkte Tore vorhanden sind.

Die Basislinie ist KEIN trivialer Schaltkreis – es ist ein richtiger, winkeltodierter Kernel, nur ohne die quantenspezifischen paarweisen Wechselwirkungsbegriffe.

HS-Prinzip 3 — Negative Ergebnisse sind erstklassige Ergebnisse

Das wahrscheinlichste empirische Ergebnis des HS-Tracks in den Jahren 2026–2027, angesichts des aktuellen Stands der Quantenhardware und des Features Map-Designs, ist, dass Quantenkernel auf biologischen Daten vergleichbar mit RBF-Kernen performen. Das ist kein Fehlschlag. Es handelt sich um eine veröffentlichungsfähige Erkenntnis, die dem Fachgebiet sagt: Aktuelle Quantenfeature-Abbildungen besitzen keine biologisch bedeutsame induktive Verzerrung, die sie von klassischen Kernen auf reellen Omics-Daten unterscheidet. Dies ist wichtiges Wissen für die Gemeinschaft und direkt relevant für die regulatorische Frage (sollten wir QML-klinischen Systemen anders vertrauen als klassischen ML-Systemen?). Die Studierenden müssen vor Beginn darüber gebrieft werden, damit sich ein Nullergebnis nicht wie eine durchgefallene Abschlussarbeit anfühlt.

HS-Prinzip 4 – Kein SHAP, kein CEL, kein CSR

Der HS-Track verwendet keine SHAP-Attribution, verwendet keine klinischen Erwartungslisten und führt keine klinische Plausibilitätsanalyse durch. Dies sind Werkzeuge zur Bewertung von Vorhersagemodellen. Der HS-Track bewertet Kernel-Matrizen – geometrische Eigenschaften des Darstellungsraums auf Populationsebene – nicht einzelne Vorhersagen. Die Bewertungsmetriken sind ARI, NMI, KTA und Delta-ARI aus der Ablation. Diese werden ohne klinische Rahmung gemeldet.

HS-Prinzip 5 — Interaktionsbehauptungen sind empirisch, nicht angenommen

Die ZZFeatureMap enthält ZZ-Rotationsterme, die paarweise Merkmalsprodukte $x_i \cdot x_j$ kodieren. Es ist verlockend zu sagen: 'Quantenkerne kodieren Wechselwirkungen.' Das ist irreführend. Der ZZ-Begriff kodiert ein spezifisches mathematisches Produkt in der Merkmalskarte – ob dies zu einer besseren Erhaltung der biologischen Interaktionsstruktur in den Daten führt, ist eine empirische Frage. Der HS-Track prüft diese Frage; Es nimmt nicht die Antwort an. Jede Dissertation muss die Formulierung verwenden: 'Die ZZFeatureMap enthält paarweise Interaktionstermen in ihrer Merkmalskarte, was die Erfassung der biologischen Interaktionsstruktur ermöglichen kann – das testen wir' statt 'Quantenkernel kodieren Interaktionen.'

Der Kontrolldatensatz: UCI-Codon-Nutzung

Warum dieser Datensatz

Der UCI-Codon-Nutzungsdatensatz (Hallee et al. 2023, Scientific Reports; Tian et al. 2024, Genome Biology and Evolution) bietet eine klare, interpretierbare Kontrolle für die Kernel-Geometrie-Pipeline, da sie: (1) eine bekannte hierarchische Clusterstruktur auf mehreren Ebenen aufweist, die unabhängig durch die Evolutionsbiologie und nicht durch die Merkmalswerte selbst bestimmt wird; (2) ausreichende Stichprobengröße für robuste Kernel-Matrix-Berechnung; (3) tabellarische Merkmale, die bereits in vergleichbarem Umfang sind; und (4) keine klinischen Störungen, die die geometrische Analyse verschleiern könnten.

Die taxonomische Hierarchie (Königreich → Stamm → Klasse → Ordnung → Familie → Gattung → Arten) liefert Grundwahrheit auf mehreren Granularitätsebenen. Zu testen, ob Quantenkerne die grobe Struktur (Königreich: 5 Klassen) besser oder schlechter erhalten als die feine Struktur (Genus: Hunderte von Klassen), ist eine reichhaltigere Validierung als eine einfache binäre Klassifikationsaufgabe. Wichtig ist, dass die Labels durch evolutionäre Beziehungen bestimmt werden – nicht durch die Werte der Codon-Nutzungsmerkmale selbst – sodass die Verwendung taxonomischer Labels zur Bewertung der Erhaltung der Clusterstruktur tatsächlich nicht-zirkulär ist.

Datensatz-Spezifikation

Eigentum	Detail
Quelle	UCI ML Repository — archive.ics.uci.edu/dataset/577/codon+usage . Keine Anmeldung erforderlich. Sofortiger Download.
Zitat	Hallee et al. (2023) Wissenschaftliche Berichte, 15 Zitationen. Tian et al. (2024) Genombiologie und Evolution, 8 Zitate.
Samples	13.028 Organismen aus dem gesamten Baum des Lebens
Merkmale	64 Codon-Nutzungsfrequenzen (CUSP-Ausgang). Werte zwischen 0 und 1. Alle Merkmale in vergleichbarem Maßstab – keine Normalisierung über die bestehende proportionale Codierung hinaus erforderlich.
Bezeichnungen	Taxonomische Bezeichnungen auf 6 Stufen: Königreich (5 Klassen), Stamm (~30), Klasse (~80), Ordnung (~200), Familie (~500), Gattung (~1.500+). Königreichsebene für die primäre Kontrolle; Genus-Ebene für Feinstrukturtest.
Warum Etiketten nicht zirkulär sind	Die taxonomische Klassifikation wird durch evolutionäre Phylogenie bestimmt – nicht durch die Verwendung von Codons. Die Frage "Clustern Quantenkernel Organismen nach taxonomischen Gruppen?" ist tatsächlich unabhängig davon, wie der Kernel entworfen wurde.
Rechenanforderungen	Für n = 200 Teilstichprobe 8 Merkmale, 8 Qubits: Die Kernel-Matrix benötigt $200 \times 200 / 2 = 20.000$ Schaltungsbewertungen. Bei ~10 ms pro Schaltung auf default.qubit: insgesamt ~3 Minuten. Vor-Benchmark auf der Supervisor-Maschine, bevor du es dem Studenten zuweisen kannst.

Spezifikation der Steuerungspipeline

Die folgende Pipeline muss auf dem UCI Codon Usage-Datensatz abgeschlossen werden, bevor ein Student biologische Daten analysiert:

- **Schritt 1 — Merkmalsauswahl:** Wählen Sie die Top-8-Merkmale nach Varianz aller 13.028 Organismen aus. Diese 8 Merkmale werden während der gesamten Steuerungsanalyse als festes Merkmalset verwendet. Dokumentieren Sie, welche 8 Codons ausgewählt werden.
- **Schritt 2 — Teilstichprobe:** Ziehen Sie eine zufällige Teilstichprobe von $n=200$ Organismen, geschichtet nach Reich (40 pro Königreich, wo möglich). Beheben Sie zufälligen Seed 42. Dies ist die primäre Analyseprobe.
- **Schritt 3 — Kernel-Berechnung:** Kernel-Matrizen berechnen für: ZZFeatureMap reps=1, ZZFeatureMap reps=2, IQP, hardwareeffizientes, verschränkungsfreies Basismodell, zufälliges unitäres Nullmodell, RBF ($\sigma=1$), Polynom (Grad=2), linear. Verwenden Sie `pennylane.kernels.kernel_matrix()` für Quanten; `sklearn.metrics.pairwise` für klassisch.
- **Schritt 4 — Cluster-Qualitätsbewertung:** Berechnen Sie ARI, NMI und KTA anhand von Kingdom-Labels für alle Kernel. Statistische Signifikanz: Reichsbezeichnungen 1.000 Mal permutieren und ARI neu berechnen. Berichte beobachtete ARI vs. Permutationsverteilung und p-Wert.
- **Schritt 5 — Ablation:** Vergleichen Sie ZZFeatureMap reps=1 mit hardwareeffizientem Baseline. Berechnen Sie Delta ARI. Dies ist das Kontrollablationsergebnis – erwartet klein oder nahezu null bei diesen Daten (die Verwendung von Codons hat möglicherweise keine starke paarweise Interaktionsstruktur). Wenn Delta nicht null ist, dokumentiere sorgfältig.
- **Schritt 6 — Feinstrukturtest:** Wiederholen Sie die Schritte 4–5 mit Stammmuster-Labels (mehr Klassen, feinkörniger). Verschlechtert sich die Qualität des Quantenkerns schneller oder langsamer als der klassische bei feinerer Granularität?
- **Schritt 7 — Visualisierung:** Kernel PCA (2D-Projektion) für alle Kernel nach Kingdom-Label gefärbt. Visuelle Überprüfung: Gruppieren sich Organismen aus demselben Reich zusammen? Dies unterstützt nur Visualisierung – ARI ist die primäre Kennzahl.

Supervisor-Pilotlauf (verpflichtend, bevor ein Schüler mit dem HS-Track beginnt)

Führen Sie die Schritte 1–5 selbst im UCI Codon Usage Dataset durch.

Das dauert etwa 2 Stunden inklusive Aufbau.

Sie erhalten: Basis-ARI-Werte für alle Kernel, Laufzeitschätzungen und eine visuelle Kontrolle.

Diese Zahlen werden zu den erwarteten Kontrollergebnissen, die Sie mit jedem Schüler teilen

So können sie überprüfen, ob ihre Umsetzung korrekt ist, bevor sie biologische Daten berühren.

Wenn Ihre Kontrollergebnisse einen Quantenkernel-ARI deutlich über dem RBF selbst bei Codondaten zeigen,

Untersuchen Sie sorgfältig – dies könnte auf einen Fehler im Ablationskreis hindeuten (Verschränkung von Gates)

nicht tatsächlich entfernt) statt eines echten Quantenvorteils auf taxonomischen Daten.

HS-A: Quantenkerneometrie und biologische Clusterstruktur

HS-A UCI Codon + TCGA-BRCA	Die Rolle der Verschränkung bei der Erhaltung biologischer Cluster: Eine Ablationsstudie von Quantenkernen in der Brustkrebs-Subtypisierung	MSc MSc · 6 Monate
---	--	------------------------------

Quantenkerneometrie und Erhaltung von Krebs-Subtyp-Clustern

FORSCHUNGSFRAGE

Bewahren Quantenkerne, die durch ZZFeatureMap und IQP-Merkmalsskizzen induziert werden, die bekannte PAM50-Molekular-Subtyp-Clusterstruktur von Brustkrebs-Multi-Omics-Daten besser als klassische Kernel (RBF, polynomiell, linear) – und ist ein Qualitätsvorteil speziell auf die Verschränkungskomponente der Merkmalskarte zurückzuführen, wie sie durch den Vergleich der vollständigen ZZFeatureMap mit einer nicht verschränkten Baseline-Schaltung mit identischer Winkelcodierung getestet wurde?

HINTERGRUND UND MOTIVATION

Das ist die grundlegende These des HS-Tracks. Bevor wir bessere Quantenfeature-Maps (HS-B) entwerfen oder die Analyse auf mehrere Omics-Schichten (HS-C) erweitern, müssen wir die empirische Basislinie festlegen: Bietet ZZFeatureMap eine sinnvoll bessere biologische Clustererhaltung als ein klassischer Kernel auf realen Krebsdaten? Die PAM50-Subtyp-Labels für TCGA-BRCA sind unabhängig validierte klinische Subtypen – nicht abgeleitet von den Genexpressionsmerkmalen selbst – was sie zu einer nicht-zirkulären Wahrheit für die Clusterqualitätsbewertung macht.

Die Eingabemerkmale (Top-8 aus dem BC-A SHAP-Ranking) verbinden diese These direkt mit dem BC-Track. Die Verwendung derselben Funktionen sowohl für die Attributionsanalyse (BC-B) als auch für die Geometrieanalyse (HS-A) ermöglicht den Cross-Track-Vergleich von Paper H4.

DATENSÄTZE

193. **Kontrolle:** UCI-Codon-Nutzungsdatensatz (13.028 Organismen, 64 Codon-Nutzungsmerkmale, Reich/Stamm-Labels). Alle Quantenschaltungsberechnungen auf dem PennyLane default.qubit-Simulator. Eine vorab festgelegte Kontrollpipeline muss abgeschlossen und überprüft werden, bevor die TCGA-BRCA-Analyse beginnt.
194. **Primär:** TCGA-BRCA (gleicher Download wie BC-Track). Eingabe: Top-8 mRNA-Features aus dem BC-A SHAP-Ranking. PAM50 wird als Grundwahrheit bezeichnet. Verwenden Sie $n=300$ stratifizierte Teilstichprobe für die Kernel-Berechnung (rechentechnisch handhabbar; Dokument-Subsampling-Verfahren).

ZIELE

- Vollständige UCI-Codon-Nutzungskontrollpipeline (Schritte 1–7 wie angegeben). Erhalte und dokumentiere Basiswerte der ARI für alle Kernel. Melde dich beim Vorgesetzten, bevor du mit der BRCA-Analyse fortgehst.

- **Berechnen Sie Quantenkernel-Matrizen auf TCGA-BRCA** ($n=300$ Teilstichprobe, 8 Merkmale): ZZFeatureMap-reps=1, ZZFeatureMap-reps=2, IQP, hardwareeffiziente, unverhedderte Basislinie, zufälliges unitäres Nullmodell. Alles auf dem PennyLane default.qubit-Simulator.
- Berechnen Sie klassische Kernel-Matrizen auf denselben Daten: RBF (σ durch Medianheuristik abgestimmt), Polynom (Grad=2,3), linear.
- **Hauptergebnis — Ablation:** Vergleichen Sie ZZFeatureMap reps=1 mit hardwareeffizientem Baseline. Delta ARI (zugeschrieben durch Verschränkung). Permutationstest (1.000 Etiketten-Umstellungen). Dies ist das Schlagzeilergebnis der These.
- Sekundäre Bewertung: ARI, NMI, Kernel Target Alignment für alle Kernel gegen PAM50-Labels. Alle Kernel nach ARI bewerten.
- Kernel-PCA-Visualisierung: 2D-Projektion für jeden Kernel, gefärbt durch den PAM50-Subtyp. Nur unterstützende Belege – eine visuelle Trennung ersetzt ARI nicht.
- Cross-Track-Verbindung: Vergleichen Sie, welche Features am meisten zur Quanten-Kernel-Trennung beitragen (pro Feature-Kernel-Beitrag, berechnet durch Leave-One-Feature-Out) mit den BC-B SHAP Top-8-Rankings. Stimmen sie zu? Dies ist die Cross-Track-Paper H4-Analyse.

METHODEN

195. **Kernberechnung:** `pennylane.kernels.kernel_matrix(kernel_fn, X)`, wobei `kernel_fn` das Quantenschaltungs-Innenprodukt $|\langle \psi(x_i) | \psi(x_j) \rangle|^2$ berechnet. Für $n=300$: $300 \times 301 / 2 = 45150$ Schaltungsbewertungen. Bei ~ 10 ms/Schaltkreis auf default.qubit: ~ 7 Minuten. Benchmark vor der Zuweisung.
196. **Feature-Codierung:** Winkelcodierung: $R_y(x_i \cdot \pi)$ pro Qubit. Funktionen, die auf $[-1, 1]$ skaliert wurden, bevor sie mit MinMaxScaler kodiert wurde, der nur auf dem Trainingsset angepasst wurde. Wende denselben Scaler auf alle Kernel-Berechnungen an.
197. **ZZFeatureMap:** PennyLane-Implementierung von ZZFeatureMap: Ry-Rotationen, gefolgt von einer CNOT-Kette, gefolgt von ZZ-verschränkten Rotationen $\exp(i \cdot x_i \cdot x_j \cdot Z \otimes Z)$ für benachbarte Qubitpaare. Wiederholungen=1 und Wiederholungen=2.
198. **Keine Entangling-Basislinie:** Nur $R_y(x_i \cdot \pi)$ -Rotationen. Kein CNOT. Kein ZZ. Gleiche 8 Qubits, dieselben 8 Features. Dies ist die Ablationskontrolle – identische Winkelkodierung ohne Verschränkung.
199. **IQP-Merkmalsabbildung:** Momentane Quantenpolynomschaltung: Hadamard-Schicht, dann diagonale Gatter $\exp(i \cdot x_i \cdot Z)$ und $\exp(i \cdot x_i \cdot x_j \cdot Z \otimes Z)$ für alle Paare. Andere Verschränkungsstruktur als ZZFeatureMap.
200. **Zufälliges unitäres Nullmodell:** Zufällig parametrisiertes unitäres Modell ohne strukturierte Merkmalscodierung. Es wird erwartet, dass es nahezu null ARI erzeugt. Bestätigt, dass jede Struktur in Quantenkernel-Ergebnissen auf Merkmalskodierung und nicht auf zufällige Schaltungseigenschaften zurückzuführen ist.
201. **Kernel-Zielausrichtung (KTA):** $KTA(K, y) = \langle K, yy^T \rangle_F / (\|K\|_F \cdot \|yy^T\|_F)$ wobei y der PAM50-Labelvektor ist. Misst die Ausrichtung zwischen Kernel-Matrix und Ideal-Label-Kernel. Höhere KTA = bessere Ausrichtung auf die biologische Struktur.
202. **Permutationstest:** PAM50-Etiketten 1.000 Mal mischen. Berechnen Sie das ARI für jedes Mischen neu. Berichte p -Wert = Anteil der Mischungen mit $ARI \geq$ beobachtetem ARI. Bewirb dich sowohl bei ZZFeatureMap als auch bei Ablation Delta.

203. **Kernelbeitrag pro Feature:** Für jedes Merkmal i berechnen Sie eine Kernmatrix mit Merkmal i , das auf eine Konstante gesetzt ist (sein Mittelwert). Delta KTA zwischen dem vollständigen Kernel und dem feature- i -entfernten Kernel = Beitrag von Merkmal i zur biologischen Ausrichtung. Berichte für alle 8 Funktionen.

LIEFERERGEBNISSE

204. Kontrollpipeline-Ergebnisse (UCI-Codon-Verwendung) — vor der BRCA-Analyse mit dem Vorgesetzten überprüft.
205. Kernel-Qualitätstabelle: Alle Kernel $\times$ ARI/NMI/KTA auf TCGA-BRCA PAM50 (primäre Ergebnistabelle).
206. Ablationsergebnis: delta ARI (ZZFeatureMap vs. No-Entangling) mit Permutationstest p-Wert — Schlagzeilenfindung.
207. Kernel-PCA-Diagramme sind nach PAM50-Subtyp gefärbt (alle Kernel, 2D, unterstützen Visualisierung).
208. Pro-Feature-Kernel-Beitragsranking vs. BC-B SHAP-Ranking (Cross-Track-Vergleichstabelle).
209. Open-Source-PennyLane-Kernel-Evaluationscode (GitHub) – zitierbar durch nachfolgende HS-Abschlussarbeiten.

VORAUSSETZUNGEN (STUDENT)

210. Starke Python. Quantencomputing-Theorie auf Zwischenebene: Hilberträume, Innerprodukte, Quantenschaltungen, Messung. Vertrautheit mit Kernel-Methoden (SVM, Kernel PCA) auf mathematischer Ebene – nicht nur als Sklearn-Werkzeuge.
211. Lies: Havlíček et al. 2018 (Nature) — grundlegende Arbeit über Quantenfeature-Räume; Schuld 2021 'Supervised quantum machine learning models are kernel methods' (PRL) – theoretische Framing; Hallee et al. 2023 (Wissenschaftliche Berichte) — UCI Codon-Anwendung von ML.
212. BC-A SHAP-Rankings müssen vorliegen, bevor die BRCA-Analyse beginnt. Koordiniere die Zeitplanung mit der BC-Strecke.

Vorbereitung des Betreuers für die HS-A

Führe den UCI Codon Usage-Pilotlauf SELBST durch, bevor du den Studenten rekrutierst.

Das dauert 2 Stunden und liefert dir: Basis-ARI-Werte, Laufzeit-Benchmarks und eine Referenz

Das Ergebnis muss der Schüler reproduzieren, bevor er fortfährt.

Vorberechnung: für $n=300$ TCGA-BRCA, 8 Features, ZZFeatureMap – wie lange dauert die Kernel-Matrix?

Erwartet: ~7 Minuten auf einer modernen CPU. Wenn >30 Minuten, untersuchen Sie – wahrscheinlich eine Schleifenineffizienz.

Das zufällige unitäre Nullmodell ist wesentlich. Wenn es nicht-triviale ARI erzeugt, stimmt etwas nicht in Ordnung

mit der Feature-Codierung (wahrscheinlich Datenleckage durch den Scaler).

Vorbereitung auf negative Ergebnisse: Besprechen Sie die drei Ergebnisszenarien mit dem Studierenden zu Beginn der Abschlussarbeit.

Szenario A (Quantenstärke besser als klassisch): Berichte die Effektgröße sorgfältig; Untersuchen Sie die Ablation.

Szenario B (quantenvergleichbar mit klassischem): publizierbares Nullergebnis; Ablation ist immer noch informativ.

Szenario C (quantenmäßig schlechter als klassisch): ebenfalls veröffentlichungsfähig; schlägt eine Struktur der Merkmalskarte vor
führt schädliche Verzerrung biologischer Ähnlichkeit ein.

HS-B: Weginformierte Verschränkung und biologische induktive Verzerrung

HS-B UCI Codon + TCGA-BRCA + TCGA- COAD	Wegbasierte Quantenfeature-Karten: Kodierung von Protein-Protein-Interaktionen in quantenmechanische Verschränkungsstrukturen	MSc MSc · 6–7 Monate
--	---	--------------------------------

Weg-informiertes Design von Quantenmerkmalen für biologische Daten

FORSCHUNGSFRAGE

Bewahrt eine Quantenfeature-Karte, deren Entangling-Gate-Struktur bekannte Protein-Protein-Interaktionsbeziehungen (PPI) widerspiegelt – also Qubits, die interagierende Genpaare auf verschränkte Qubit-Paare repräsentieren – die Struktur des Krebssubtyp-Clusters besser als eine Merkmalskarte mit zufälliger Verschränkungsstruktur (unter Kontrolle der Anzahl der verschränkten Gates), und hält sich eine Verbesserung, wenn sie auf einem zweiten Krebsdatensatz repliziert wird?

HINTERGRUND UND MOTIVATION

HS-A stellt fest, ob ZZFeatureMap die biologische Struktur bewahrt. HS-B stellt eine Designfrage: Können wir generisches ZZFeatureMap verbessern, indem wir biologisches Wissen in die Entanglement-Struktur kodieren? Die Idee ist durch die Beobachtung motiviert, dass die ZZ-Gatter des ZZFeatureMap paarweise Korrelationen zwischen Qubit i und Qubit j erzeugen, entsprechend dem Merkmalspaar (x_i, x_j) . Wenn wir Qubits Gene zuweisen, sodass bekannte Interaktionspartner auf verschränkten Qubitpaaren platziert werden, kann der Quantenkern biologisch relevante Kovariation besser erfassen.

Dies ist analog zu physikbasierten neuronalen Netzen – das kodiert Domänenwissen in die Modellarchitektur. Es ist eine wirklich neuartige Idee: Keine veröffentlichte Arbeit hat Quantenmerkmalekarten auf Basis biologischer Interaktionsnetzwerke für klinische Omics-Daten entwickelt.

Dependenzgatter: HS-A muss zuerst abgeschlossen werden

HS-B sollte erst beginnen, wenn die HS-A-Ergebnisse vorliegen.

Wenn HS-A zeigt, dass die No-Entangling-Baseline mit ZZFeatureMap in Clusterqualität übereinstimmt (Delta-ARI nicht signifikant von null unterscheidet), ist die Motivation für HS-B geschwächt:

wenn Verschränkung im generischen ZZFeatureMap nichts hinzufügt, ist pfadinformierte Verschränkung kann auch nichts hinzufügen. In diesem Fall leiten Sie HS-B auf eine diagnostische Frage um:

'Warum trägt Verschränkung nicht zur biologischen Clustererhaltung bei?' —

was selbst eine veröffentlichungsfähige Erkenntnis mit wichtigen QML-Implikationen ist.

Verpflichten Sie sich nicht zu HS-B, bevor Sie die HS-A-Ergebnisse mit dem Schüler geprüft haben.

DATENSÄTZE

213. **Kontrolle:** UCI-Codon-Verwendung (wie HS-A, mit pfadbasiertem Äquivalent: Verwendung bekannter Codon-Bias-Korrelationen als 'Interaktions'-Vorstufe für das Kontrollexperiment).
214. **Primär:** TCGA-BRCA (gleiche Daten und Funktionen wie HS-A). Weginformierte Verschränkung basierend auf STRING-DB-Interaktionen zwischen den Top-8 SHAP-Genen.
215. **Replikation:** TCGA-COAD/READ (gleiche Daten wie CRC-Track). Nutzen Sie Top-8-Features von CRC-A SHAP. CMS1/CMS4 bezeichnet sie als Bodenwahrheit. Replikationstests testen die Generalisierbarkeit jedes Befunds über einen einzelnen Krebstyp hinaus.

ZIELE

- Vollständige UCI-Codon-Nutzungskontrollpipeline (wie bei HS-A). Zusätzlich: Konstruiere eine 'korrelationsbasierte' Merkmalskarte für die Kontrolle, bei der Merkmale mit hoher paarweiser Pearson-Korrelation auf verschränkten Qubits platziert werden. Im Vergleich zu zufälliger Verschränkung. Dies ist das Kontroll-Analogon des pathway-informed experiments.
- **STRING-DB-Interaktionsmatrix:** Abfrage aller Paare unter den 8 größten BC-A-Shap-Genen bei string-db.org. Export-Interaktions-Vertrauenswerte. Schwelle bei $\geq 0,7$ (hohe Zuverlässigkeit). Konstruiere binäre Adjazenzmatrix A , bei der $A[i,j]=1$, wenn das Genpaar (i,j) eine Vertrauenswürdigkeit $\geq 0,7$ hat.
- **Pfadbasiertes ZZFeatureMap:** Modifiziere ZZFeatureMap so, dass ZZ-Verschränkungen nur zwischen Qubitpaaren (i,j) platziert werden, wobei $A[i,j]=1$. Implementiere als benutzerdefinierte PennyLane QNode.
- **Nullverteilung (verpflichtend):** Generiere 100 zufällige Qubit-Zuweisungen – genauso viele Verschränkungen wie die pfadbasierte Schaltung, aber zufällig ausgewählte Qubitpaare. Berechne für jede ARI. Melde den Mittelwert $\pm$ SD der zufälligen ARI-Verteilung. Das pathway-informierte ARI muss mit dieser Nullverteilung verglichen werden, nicht nur mit dem No-Entangling-Baseline.
- Bewerten: pathway-basierte ARI vs. Nullverteilungs-Mittelwert ARI vs. HS-A ZZFeatureMap-ARI vs. no-entangling-Baseline-ARI. Statistischer Test: z-Wert des signalpfadinformierten ARI relativ zur Nullverteilung.
- Beitrag pro Paar-Gatter: Für jedes verschränkte Gatter (i,j) in der pfadbasierten Schaltung berechnet man das Leave-One-Gate-out Delta-KTA. Korrelation mit STRING-DB-Vertrauenswerten. Vorgegebene Frage: Tragen PPI-Paare mit höherer Zuverlässigkeit mehr zur biologischen Ausrichtung bei als Paare mit niedrigerer Zuverlässigkeit?
- Replikation auf TCGA-COAD: Wenden Sie dasselbe pathway-basierte Design auf CRC-Track-Top-8-Features an. Hält das Muster (pathway-gestützt > zufällig > nicht verhedderbar) bei einem zweiten Krebstyp fest?

METHODEN

216. **STRING-DB-Abfrage:** Python `stringdb` Library: `stringdb.get_interaction_partners(gene, species=9606)`. Benutze `combined_score` Spalte. Schwelle 0,7. Exportiere in die Adjazenzmatrix. Dokumentieren Sie, wie viele Paare über dem Schwellenwert der 8 BRCA-Gene liegen.
217. **Benutzerdefinierte PennyLane-Schaltung:** Implementiere pfadbasierte ZZFeatureMap als PennyLane-Vorlage. Parameter: Liste der verschränkten Paare (i,j) aus der Adjazenzmatrix. Überprüfen Sie, dass das Setzen aller Paare auf $A[i,j]=1$ den Standard-ZZFeatureMap reproduziert.

218. **Nullverteilung:** Für jede der 100 zufälligen Permutationen wählen Sie zufällig die gleiche Anzahl von Qubitpaaren wie in der pfadbasierten Schaltung (ohne Ersatz). Berechnen Sie Kernel-Matrix und ARI. Dies ergibt die empirische Nullverteilung für die 'zufällige Gleich-n-Gates-Verschrankung'.
219. **Beitrag pro Paar-Gatter:** Für jedes Gatter (i,j) in einer pfadbasierten Schaltung: Dieses Gatter auf Identität setzen (entfernen), Kernel-Matrix und KTA neu berechnen. Delta KTA = Gate-Beitrag. Spearman-Korrelation zwischen Gate-Beiträgen und STRING-DB-Vertrauenswerten.
220. **Replikation:** Identische Pipeline auf TCGA-COAD Top-8 CRC-A SHAP-Funktionen anwenden. STRING DB Abfrage für diese 8 Gene. Gleiche zufällige Nullverteilung mit 100 Permutationen.

LIEFERERGEBNISSE

221. Kontrollergebnisse: korrelationsbasierte vs. zufällige Verschrankung bei der Verwendung von UCI-Codons.
222. STRING DB Adjacenzmatrix für BRCA Top-8-Gene (dokumentiert, geteilt mit HS-A zum Kreuzvergleich).
223. Nullverteilungsdiagramm: 100 ARI-Werte mit zufälliger Verschrankung und pfadbasierter ARI markiert. Hauptergebnisfigur.
224. Pathway-informed vs. HS-A-Benchmarks: Vergleichstabelle (pathway-informed, random null mean, ZZFeatureMap, no-entangling, RBF).
225. Der Beitrag pro Paargatter vs. STRING-DB-Konfidenzkorrelation (Spearman r mit p -Wert).
226. TCGA-COAD-Replikationsergebnisse.
227. Open-Source-Pfad-basierte PennyLane-Schaltvorlage (GitHub).

VORAUSSETZUNGEN (STUDENT)

228. HS-A-Pipeline verfügbar und verstanden. Schüler der HS-B sollten vor Beginn den HS-A-Code lernen.
229. Netzwerkbiologie: Protein-Protein-Interaktionsnetzwerke, STRING DB, Signalwegdatenbanken.
230. Lesetext: zusätzlich zur HS-A-Leseliste — Bhagavatham et al. 2022 (RA Multi-Omics) zur Motivation; Schuld & Killoran 2022 für induktive Bias-Framing in QML.

Betreuernotizen für HS-B

Die Nullverteilung (100 zufällige Permutationen) ist das wichtigste methodische Element. Ohne sie kann man 'pathway-informed entanglement helps' nicht von 'pathway-informed entanglement helps' nicht unterscheiden

'Jede Verschrankung mit derselben Dichte hilft'. Stellen Sie sicher, dass der Schüler alle 100 Permutationen durchführt.

STRING DB Schwellenempfindlichkeit: Wiederhole die STRING DB Adjacenzmatrix-Konstruktion bei den Schwellenwerten 0,4 und 0,9 sowie bei 0,7. Berichten, ob die Anzahl der verhedderten Paare und das ARI-Ergebnis ändert sich erheblich. Das ist die Robustheitsprüfung.

Wenn pathway-informed nicht besser ist als der zufällige Nullmittelwert: Formulieren Sie dies als 'aktuelle STRING-Datenbank

Interaktionsdaten bieten keine nützliche induktive Verzerrung für das Design von Quantenkernen Funktionssatz" – ein spezifisches, informatives Nullergebnis, kein allgemeines Scheitern.

Replikation auf TCGA-COAD: CRC-A SHAP-Rankings benötigen, bevor HS-B beginnt.
Koordiniere dich mit der CRC-Streckenzeit.

HS-C: Multi-Omics-Quantenkernegeometrie

HS-C

UCI Codon +
TCGA-BRCA
Multi-Omics

Multi-Omics-Integration in Quantenfeature-Räume: Geometrische Komplementarität und Kernfusion für die klinische Klassifikation

MSc

MSc · 6–7 Monate

Geometrie des Quantenkerns über Omics-Schichten hinweg und Kernfusion

FORSCHUNGSFRAGE

Kodieren Quantenkerne, die aus verschiedenen Omics-Schichten (mRNA-Expression, DNA-Methylierung, MiRNA, Kopienzahl-Alteration) derselben Tumorproben berechnet werden, eine andere geometrische Struktur – gemessen durch inter-kernelzentrierte Kernel-Ausrichtung – und verbessert die Fusion dieser Kernel (gewichtete Kombination) die Qualität des PAM50-Subtyp-Clusters gegenüber jedem einzelnen Quantenkern oder dessen klassischem Gegenstück?

HINTERGRUND UND MOTIVATION

HS-A konzentriert sich auf eine einzelne Omics-Schicht (mRNA). HS-C stellt eine Multi-Omics-Geometrie-Frage: Codierte jede Omics-Schicht eine andere geometrische Ansicht derselben biologischen Realität, und können diese Ansichten sinnvoll kombiniert werden? Die klassische Multi-Omics-Literatur (Cantini et al. 2021, Nature Communications — Benchmark von 9 gemeinsamen Dimensionsreduktionsmethoden auf TCGA) zeigt, dass verschiedene Omics-Schichten komplementäre Informationen zur Überlebensvorhersage beitragen. Ob Quantenkerne aus verschiedenen Omics-Schichten geometrisch komplementär oder redundant sind, ist unerforscht.

Diese Arbeit hängt nicht von HS-B-Ergebnissen ab und kann parallel zu HS-B laufen, sofern der Pipeline-Code von HS-A verfügbar ist.

DATENSÄTZE

231. **Kontrolle:** UCI-Codon-Nutzung (wie HS-A/HS-B). Zusätzlich: Teile die 64-Codon-Merkmale in zwei beliebige Gruppen zu je 32 auf. Behandle das Kontroll-Inter-Kernel-Alignment-Experiment als 'zwei Omics-Schichten'.
232. **Primär:** TCGA-BRCA vier Omics-Schichten: mRNA (Top-8 nach Varianz aus dem BC-A SHAP-Pool), DNA-Methylierung (Top-8 CpG-Stellen nach Varianz, wobei bevorzugt Promoter-Region-Stellen der CEL-Gene erhalten werden), miRNA (Top-8 miRNA nach Varianz), Kopienzahl-Alteration (Top-8 Gen-Level CNA-Werte). Alle auf demselben Sample-Set (Schnittmenge; erwarten Sie ~700–800 BRCA-Samples mit allen vier Schichten). Alle Quantenschaltungsberechnungen auf dem PennyLane default.qubit-Simulator.

ZIELE

- UCI-Codon-Nutzungskontrolle: 64 Funktionen werden in zwei Gruppen zu je 32 aufgeteilt. Berechnen Sie für jede Gruppe den ZZFeatureMap-Kernel. Berechnen Sie die zentrierte Kernel-Ausrichtung (CKA) zwischen den beiden partiellen Kernen. Dies legt fest, wie 'komplementär vs. redundant' in einem kontrollierten Umfeld aussieht.
- **Einschichtige Kerne (4 Quanten + 4 klassisch):** Für jede Omics-Schicht (mRNA, Methylierung, miRNA, CNA) berechnen Sie den ZZFeatureMap-Kernel und den RBF-Kernel. Vergleichen Sie jede mit PAM50-Labels mit ARI, NMI, KTA. Rangfolge Omics-Schichten nach biologischer Ausrichtungsqualität.

- **Inter-layer CKA-Matrix:** Berechnen Sie die zentrierte Kernel-Ausrichtung zwischen allen Paaren der 4 Quantenkerne. Melde dich als 4×4-Heatmap. High CKA = Kernel kodieren eine ähnliche geometrische Struktur (redundant). Low CKA = Kernel kodieren eine andere Struktur (komplementär). Dies ist das primäre beschreibende Ergebnis.
- **Kernfusion:** Kombinieren Sie einschichtige Kernel nach gewichteter Summe: $K_{\text{fused}} = \sum w_i \cdot K_i$. Zwei Fusionsstrategien: (a) gleiche Gewichte ($w_i = \text{jeweils } 0,25$), (b) KTA-optimierte Gewichte (maximieren Sie die KTA des fusionierten Kernels gegenüber PAM50-Labels mit `scipy.optimize`, 5-facher CV zur Verhinderung von Überanpassungen). Bewerten Sie den fusionierten Quantenkernel vs. den fusionierten klassischen Kernel vs. den besten einschichtigen Kernel.
- Klassischer Vergleich: Gleiche Fusionspipeline auf RBF-Kernel für jede Omics-Schicht anwenden. Zeigen klassische fusionierte Kernel das gleiche Komplementaritätsmuster wie quantenfusionierte Kerne?
- **Analyse des Schichtbeitrags:** Entfernen Sie jeweils eine Schicht aus der 4-Kern-Fusion. Delta KTA = eindeutiger Beitrag dieser Schicht. Gib an, welche Omics-Ebene für die PAM50-Subtyp-Geometrie am einzigartigsten ist.

METHODEN

233. **Zentrierte Kernel-Ausrichtung (CKA):** $CKA(K_1, K_2) = \langle K_{1_c}, K_{2_c} \rangle_F / (\|K_{1_c}\|_F \cdot \|K_{2_c}\|_F)$ wobei $K_c = HKH$, $H = I - (1/n)11^T$ die Zentrierungsmatrix ist. Implementiere alles von Grund auf (sklearn hat CKA nicht nativ). Vergleiche es mit der veröffentlichten Formel.
234. **Methylierungsmerkmale:** Verwenden Sie M-Werte (Beta-Logit). Wählen Sie die Top-8 nach Varianz über alle BRCA-Stichproben hinweg aus, behalten Sie jedoch bevorzugt CpG-Stellen in Promotorregionen der Tier-1/2-CEL-Gene, wenn diese nach Varianz zu den Top-20 gehören.
235. **miRNA: log2 (RPM+1) normalisierte miRNA-Expression.** Top-8 nach Varianz. Diese werden hauptsächlich OncomiR- und tumorsuppressor-miRNAs sein – für diese Schicht ist keine spezifische CEL-Vorspezifikation erforderlich.
236. **CNA:** Gen-ebene Kopierzahlwerte (GISTIC2 Ausgabe von GDC). Top-8-Gene nach CNA-Varianz. Wahrscheinlich werden ERBB2 (HER2-Amplifikation relevant für HER2-angereicherten Subtyp) und 8p/17q-chromosomale Regionen umfassen.
237. **KTA-Optimierung:** `scipy.optimize.minimize(negative_KTA, initial_weights=[0.25,0.25,0.25,0.25], bounds=[(0,1)]*4, constraints={'type':'eq','fun': lambda w: sum(w)-1})`. Verwenden Sie 5-fache CV: Optimieren Sie Gewichte bei 4 Falten, bewerten Sie bei gehaltenem Falten. Berichte $\pm$ SD KTA über Falten hinweg.
238. **Probenschnitt:** TCGA-BRCA hat möglicherweise nicht alle vier Omics-Schichten für alle Proben. Verwenden Sie Inner Join über alle vier Datenmatrizen. Dokumentiere n vor und nach der Kreuzung. Wenn $n < 400$ nach der Schnittsektion liegt, beschränken Sie sich auf 3 Schichten (mRNA + Methylierung + miRNA) und dokumentieren.

LIEFERERGEBNISSE

239. Control CKA-Experiment: Komplementarität von zwei Kernen mit partieller Codon-Verwendung.
240. Einschichtige ARI/NMI/KTA-Tabelle (4 Quanten + 4 klassische Schichten). Welche Schicht codiert die beste biologische Struktur?
241. 4×4 Inter-Layer CKA-Heatmap (primäre beschreibende Figur).
242. Kernel-Fusionsvergleich: gleichgewichtig vs. KTA-optimiert vs. bestes einschichtiges vs. klassisches Äquivalent.

- 243. Analyse des Beitrags der Schicht: eindeutige Delta-KTA pro Omics-Schicht.
- 244. Open-Source-Multi-Omics-Kernel-Fusionscode (GitHub).

VORAUSSETZUNGEN (STUDENT)

- 245. HS-A-Pipeline verfügbar und verstanden. HS-C kann 1–2 Monate nach Beginn von HS-A beginnen (erfordert keine HS-A-Ergebnisse, sondern nur den HS-A-Code).
- 246. Multi-omics-Datenkompetenz: Verstehen Sie, was mRNA, Methylierungs-M-Werte, miRNA und CNA biologisch messen und wie sie sich unterscheiden.
- 247. Lies: Cantini et al. 2021 (Nature Communications – Multi-Omics-Integrations-Benchmark); Rappoport & Shamir 2018 (Nukleinsäureforschung – Multi-Omics-Clustering).

Betreuer-Notizen für HS-C

TCGA-BRCA-Stichprobenschnitt: Überprüfen Sie n mit allen vier Schichten vor der Vergabe der These. Führe diese Abfrage in R mit TCGAbiolinks aus: zähle Proben mit mRNA + Methylierung + miRNA + CNA. Erwarten Sie ~700–800. Bei weniger als 400 streichen Sie CNA (niedrigste klinische Relevanz für diesen Vergleich).

CKA-Implementierung: Es gibt keine standardisierte Sklearn-CKA-Funktion. Der Schüler muss es umsetzen.

Verweisen Sie sie auf Kornblith et al. 2019 (ICML) für die korrekte Formel und numerische Stabilitätsnotizen.

Überanpassungsrisiko der KTA-Optimierung: Die optimierten Gewichte müssen quervalidiert werden. Ohne CV passen sich die Gewichte übermäßig an die verwendete Teilprobe an.

Die Haupteinzählung: Wenn Methylierungs- und mRNA-Kerne einen niedrigen CKA (komplementär) haben, Fusion sollte helfen. Wenn sie eine hohe CKA (redundant) haben, fügt Fusion nichts hinzu.

Beide Ergebnisse sind interessant. Formulieren Sie beide mit dem Schüler vor, bevor die Ergebnisse vorliegen.

TODO: Datenzugriff: TCGA über das GDC-Portal (sofort). ADNI: Antrag jetzt einreichen (2-wöchige Bearbeitung). PPMI: Bewerbung jetzt einreichen. GEO-Datensätze: sofort herunterladen, überprüfen, ob die Batch-Korrektur-Pipeline funktioniert.